

Федеральное государственное автономное образовательное учреждение высшего образования

**НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ  
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»**

Факультет компьютерных наук  
образовательная программа «Науки о данных»

**КУРСОВАЯ РАБОТА**

**Предсказание высоковлатильных временных рядов с помощью  
моделей нейронных сетей**

---

Выполнил:  
Студент группы группы МНКДН251  
Григорян Тигран Артурович

Руководитель:  
преподаватель, магистр  
Слаболицкий Илья Сергеевич

# Оглавление

|                                                                                                     |           |
|-----------------------------------------------------------------------------------------------------|-----------|
| <b>Аннотация</b>                                                                                    | <b>3</b>  |
| <b>Annotation</b>                                                                                   | <b>4</b>  |
| <b>Введение</b>                                                                                     | <b>5</b>  |
| Актуальность темы исследования . . . . .                                                            | 5         |
| Цель и задачи исследования . . . . .                                                                | 6         |
| Объект и предмет исследования . . . . .                                                             | 6         |
| Методы исследования . . . . .                                                                       | 7         |
| Научная новизна . . . . .                                                                           | 7         |
| Практическая значимость . . . . .                                                                   | 8         |
| Структура работы . . . . .                                                                          | 8         |
| <b>1 Обзор литературы и теоретические основы</b>                                                    | <b>9</b>  |
| 1.1 Прогнозирование финансовых временных рядов: эффективность рынка и случайное блуждание . . . . . | 9         |
| 1.2 Глубокое обучение для прогнозирования временных рядов . . . . .                                 | 9         |
| 1.3 Классификация направления против регрессии уровней . . . . .                                    | 11        |
| 1.4 Признаки: технические индикаторы, on-chain, деривативы и сентимент . . . . .                    | 11        |
| 1.5 Нестационарность, смена режимов и стилизованные факты . . . . .                                 | 11        |
| 1.6 Методология валидации финансового машинного обучения и переобучение . . . . .                   | 12        |
| 1.7 Метрики качества: коэффициент Мэтьюса и экономические критерии . . . . .                        | 12        |
| 1.8 Выводы по главе и обоснование настоящей работы . . . . .                                        | 13        |
| <b>2 Постановка задачи и методология</b>                                                            | <b>14</b> |
| 2.1 Формальная постановка трёхклассовой задачи . . . . .                                            | 14        |
| 2.2 Три постановки задачи . . . . .                                                                 | 15        |
| 2.3 Типы целевой переменной . . . . .                                                               | 16        |
| 2.4 Нейросетевые модели и базовые модели сравнения . . . . .                                        | 17        |
| 2.5 Валидация: purged + embargoed walk-forward как операционная петля . . . . .                     | 17        |
| 2.6 Метрики, статистическая значимость и экономическая оценка . . . . .                             | 18        |
| <b>3 Данные и признаки</b>                                                                          | <b>19</b> |
| 3.1 Базовый ценовой ряд . . . . .                                                                   | 19        |
| 3.2 Экзогенные данные: крипто-нативные, а не макроэкономические . . . . .                           | 19        |
| 3.3 Проектирование признаков . . . . .                                                              | 20        |
| 3.4 Пропуски, структурное отсутствие и воспроизводимость . . . . .                                  | 20        |

|          |                                                                  |           |
|----------|------------------------------------------------------------------|-----------|
| <b>4</b> | <b>Дизайн экспериментов</b>                                      | <b>22</b> |
| 4.1      | Принципиальный эксперимент: нейросети против базлайнов . . . . . | 22        |
| 4.2      | Рамка постановок и абляции . . . . .                             | 22        |
| 4.3      | Оборудование и воспроизводимость . . . . .                       | 23        |
| 4.4      | Результаты . . . . .                                             | 23        |
|          | <b>Заключение</b>                                                | <b>24</b> |
|          | <b>Список литературы</b>                                         | <b>25</b> |

## Аннотация

Работа посвящена предсказанию высоковолатильных финансовых временных рядов с помощью моделей нейронных сетей. В качестве канонического представителя такого ряда выбран биткойн: задача формулируется как прогнозирование *направления* его цены на горизонте 24 часа — классификация на три класса  $\{-1, 0, +1\}$  на часовых данных BTC/USDT с фиксированным порогом  $\pm 2\%$  (класс  $+1$  — значимый рост,  $-1$  — значимое падение,  $0$  — отсутствие значимого движения, «флэт»). Переход от прогноза уровня цены к прогнозу направления мотивирован тем, что регрессия на уровне высоковолатильного ряда вырождается в ловушку случайного блуждания и не несёт реальной предсказательной силы о движении.

Центральный объект изучения — *нейросетевые модели* двух типов представления данных: табличный многослойный перцептрон на инженерных признаках и *последовательностные* модели (GRU, LSTM, причинная свёрточная сеть TCN) на строго каузальных окнах исходных каналов. Исследуются три вопроса: (i) способны ли нейронные сети предсказывать направление высоковолатильного ряда и какие архитектуры предпочтительны; (ii) как способ постановки задачи влияет на качество — сравниваются три декомпозиции одной и той же трёхклассовой задачи (единая softmax-голова; две независимые бинарные модели; каскад «гейт  $\rightarrow$  направление»); (iii) даёт ли выразительная сила нейронных сетей преимущество над *сильными базовыми моделями* градиентного бустинга при дефиците эффективно-независимых наблюдений, характерном для высоковолатильных режимов.

Методология подчинена приоритету честности оценки: строго каузальные признаки и каузальные окна, purged + embargoed walk-forward валидация как операционная петля, отбор по коэффициенту Мэтьюса (MCC) вместо доли верных ответов, экономическая оценка с издержками и статистические поправки на множественное тестирование (Deflated Sharpe Ratio, Probability of Backtest Overfitting, тест Дибольда–Мариано). Текст содержит постановку задачи, обзор литературы, методологию, описание данных и признаков и дизайн экспериментов; раздел эмпирических результатов оставлен заготовкой и будет заполнен после полного вычислительного прогона.

**Ключевые слова:** высоковолатильные временные ряды, нейронные сети, глубокое обучение, рекуррентные сети, LSTM, GRU, TCN, прогнозирование направления, классификация временных рядов, биткойн, purged walk-forward, нестационарность, коэффициент Мэтьюса.

# Annotation

This thesis addresses the prediction of highly volatile financial time series using neural network models. Bitcoin is taken as the canonical instance of such a series: the task is formulated as predicting the *direction* of its price over a 24-hour horizon — a three-class classification  $\{-1, 0, +1\}$  on hourly BTC/USDT data with a fixed  $\pm 2\%$  threshold (+1 a significant rise,  $-1$  a significant fall, 0 the absence of significant movement, “flat”). Moving from level to direction forecasting is motivated by the fact that regression on the levels of a highly volatile series collapses into the random-walk trap.

The central object of study is a family of *neural network models* over two data representations: a tabular multilayer perceptron on engineered features and *sequence* models (GRU, LSTM, and a causal temporal convolutional network, TCN) on strictly causal windows of the raw channels. Three questions are investigated: (i) whether neural networks can predict the direction of a highly volatile series and which architectures are preferable; (ii) how the problem formulation affects quality — three decompositions of the same three-class task are compared (a single softmax head; two independent binary models; a gate→direction cascade); and (iii) whether the expressive power of neural networks yields an advantage over *strong gradient-boosting baselines* given the scarcity of effectively independent observations characteristic of high-volatility regimes.

Validation relies on strictly causal features and windows, purged and embargoed walk-forward treated as an operational loop, selection by the Matthews correlation coefficient, cost-aware economic evaluation, and corrections for multiple testing (Deflated Sharpe Ratio, Probability of Backtest Overfitting, Diebold–Mariano). The empirical results section is left as a placeholder to be completed after the full computational run.

**Keywords:** highly volatile time series, neural networks, deep learning, recurrent networks, LSTM, GRU, TCN, direction forecasting, time-series classification, Bitcoin, purged walk-forward, non-stationarity, Matthews correlation coefficient.

# Введение

## Актуальность темы исследования

Высоковолатильные финансовые временные ряды — одна из наиболее трудных для прогнозирования категорий данных. Их характерные свойства — экстремальная волатильность с кластеризацией, тяжёлые хвосты распределения, структурные сдвиги и смена режимов — нарушают предположения классических статистических моделей. Каноническим представителем такого ряда служит биткойн: за полтора десятилетия с момента публикации его протокола [1] он прошёл путь от нишевого криптографического эксперимента до класса активов с капитализацией, превышающей триллион долларов США, торгуется круглосуточно и без выходных и демонстрирует спекулятивные пузыри и быстрые обвалы. Рост институционального интереса и появление производных инструментов усилили спрос на количественные методы прогнозирования и управления риском на таких рынках.

В последнее десятилетие методы *глубокого обучения* преобразили прогнозирование временных рядов: рекуррентные сети (LSTM), свёрточные и основанные на механизме внимания (трансформерные) архитектуры стали стандартом и активно применяются к криптовалютам и другим высоковолатильным рядам [5, 6, 8, 9, 10, 11]. Способность нейронных сетей улавливать нелинейные и временные зависимости делает их естественным кандидатом для прогнозирования *направления* движения высоковолатильного ряда. Вместе с тем уместность нейросетевых моделей в этой задаче далеко не очевидна: рынок близок к информационно эффективному, знак приращений цены ведёт себя как близкий к белому шуму процесс, а прогноз *уровня* упирается в ловушку случайного блуждания [2, 4]. Это смещает интерес к прогнозированию направления и одновременно ставит вопрос: даёт ли выразительная сила нейронных сетей реальное преимущество там, где сигнал слаб, а данных эффективно мало?

Актуальность настоящей работы определяется двумя обстоятельствами. Во-первых, несмотря на обилие нейросетевых моделей прогнозирования высоковолатильных рядов, в литературе доминируют работы, предлагающие *одну* архитектуру и демонстрирующие её превосходство на единичном разбиении данных; систематического, честного по утечкам сравнения нейросетевых архитектур между собой, с сильными базовыми моделями и при разных способах *постановки* задачи практически не проводится. Во-вторых, значительная доля заявленных результатов получена без надлежащего контроля утечек данных, нестационарности и множественного тестирования, что в условиях большого числа параметров нейронных сетей особенно опасно и подрывает воспроизводимость [12]. Настоящая работа отвечает на оба вызова, проводя честную по методологии оценку нейросетевых моделей для предсказания направления высоковолатильного ряда.

## Цель и задачи исследования

**Цель исследования** — исследовать применимость моделей нейронных сетей к предсказанию направления высоковолатильных финансовых временных рядов (на примере биткоина), методологически строго и честно по утечкам сравнить нейросетевые архитектуры между собой, с сильными базовыми моделями и при разных способах постановки задачи, и установить границы предсказуемости направления на часовом горизонте.

Для достижения цели поставлены следующие **задачи**:

1. провести обзор литературы по нейросетевым методам прогнозирования временных рядов и высоковолатильных финансовых рынков, методологии валидации финансовых моделей и метрикам качества;
2. формализовать задачу прогнозирования направления как трёхклассовую классификацию и обосновать ключевые проектные решения (классификация вместо регрессии, третий «флэт»-класс, сравнение трёх постановок);
3. собрать и подготовить данные: часовой ряд BTC/USDT и крипто-нативные экзогенные источники, спроектировать строго каузальный набор признаков и каузальное оконное представление для последовательностных нейросетей;
4. реализовать нейросетевые модели (табличный многослойный перцептрон и последовательностные GRU/LSTM/TCN) в трёх постановках задачи, а также базовые модели градиентного бустинга для честного сравнения;
5. построить честную процедуру валидации без утечек данных (purged + embargoed walk-forward), включая автоматические тесты утечки для нейронных сетей, и протокол отбора моделей;
6. спроектировать сравнение нейросетевых архитектур, постановок задачи и базовых моделей по статистическим и экономическим критериям с поправками на множественное тестирование;
7. сформулировать выводы о границах применимости нейронных сетей и направления дальнейшего улучшения.

## Объект и предмет исследования

**Объект исследования** — высоковолатильные финансовые временные ряды; канонический представитель — биткоин (часовой ценовой ряд BTC/USDT и сопутствующие крипто-нативные данные: деривативы, потоки сделок, on-chain показатели, рыночный сентимент).

**Предмет исследования** — нейросетевые модели прогнозирования направления движения высоковолатильного ряда, способы постановки (декомпозиции) трёхклассовой задачи, а также методология честной валидации и сравнения нейронных сетей с базовыми моделями.

## Методы исследования

В работе используются методы *глубокого обучения* — полносвязные (многослойный перцептрон), рекуррентные (GRU, LSTM) и причинные свёрточные (TCN) нейронные сети, — а в качестве сильных базовых моделей — градиентный бустинг над решающими деревьями. Применяются методы математической статистики и анализа временных рядов (проверки стационарности, автокорреляционный анализ, анализ режимов волатильности), методология валидации финансового машинного обучения по Лопесу де Прадо (purged  $k$ -fold, комбинаторная очищенная кросс-валидация, walk-forward) [12], аппарат статистической оценки значимости (Deflated Sharpe Ratio, вероятность переобучения бэктеста, тест Дибольда–Мариано) [13, 14, 15] и экономическое бэктестирование торговой стратегии с явной моделью издержек.

## Научная новизна

Научная новизна работы состоит в следующем.

1. Впервые проводится *like-for-like* сравнение трёх постановок трёхклассовой задачи направления (совместная softmax-голова против двух независимых бинарных моделей против каскада «гейт  $\rightarrow$  направление») для *нейросетевых моделей* высоковолатильного ряда при строго зафиксированных прочих условиях, что позволяет изолировать влияние самого способа декомпозиции на качество прогноза и экономику.
2. Проведено честное (leakage-honest) сопоставление *табличных и последовательностных* нейросетевых архитектур (многослойного перцептрона против GRU/LSTM/TCN) между собой и с сильными базовыми моделями градиентного бустинга при дефиците эффективно-независимых наблюдений, характерном для высоковолатильных режимов, — с каузальным оконным представлением и автоматическими тестами утечки, адаптированными к нейронным сетям; дополнительно предложен режим-нормализованный вариант целевой переменной (vol-scaled), корректирующий зависимость дисбаланса классов от рыночного режима.
3. Реализована честная по утечкам и нестационарности методология оценки: purged + embargoed walk-forward как операционная петля, строгий контроль каузальности признаков и окон с автоматическими тестами утечки, а также сквозной учёт множественного тестирования через Deflated Sharpe Ratio и вероятность переобучения бэктеста по всему фактическому гриду конфигураций.



## Практическая значимость

Практическая значимость работы определяется тем, что она даёт реалистичную, воспроизводимую оценку границ применимости нейросетевых моделей к предсказанию направления высоковолатильных финансовых рядов: какие архитектуры (табличные или последовательностные) и при какой постановке задачи оправданы и в каких условиях они уступают простым базовым моделям. Предложенная методология и программная реализация образуют инструментарий для честной оценки предсказуемости, позволяют формировать реалистичные ожидания относительно достижимого качества и служат основой для построения и риск-контроля торговых стратегий, а также методическим ориентиром для последующих исследований в области прогнозирования высоковолатильных рядов методами глубокого обучения.

## Структура работы

Работа состоит из введения, четырёх глав, заключения и списка литературы. В первой главе приводится обзор литературы и теоретические основы. Во второй главе формализуется постановка задачи и излагается методология (три постановки, типы целевой переменной, схема валидации, метрики и экономическая оценка). Третья глава описывает данные и проектирование признаков. Четвёртая глава содержит дизайн экспериментов; раздел эмпирических результатов оставлен заготовкой. В заключении подводятся итоги и намечаются направления дальнейшей работы.

# 1 Обзор литературы и теоретические основы

## 1.1 Прогнозирование финансовых временных рядов: эффективность рынка и случайное блуждание

Теоретической отправной точкой при моделировании цен финансовых активов служит гипотеза эффективного рынка, согласно которой цены полностью и мгновенно отражают доступную информацию [2]. В слабой форме эффективности информационное множество ограничено прошлыми ценами и объёмами; из неё следует, что приращения цены не предсказуемы из прошлых цен сверх равновесной премии за риск, а ряд лог-доходностей  $r_t = \ln(S_t/S_{t-1})$  с точностью до первого приближения ведёт себя как последовательность некоррелированных случайных величин. Эмпирически это проявляется в практически плоской автокорреляционной функции доходностей при наличии выраженной автокорреляции их модулей и квадратов — эффекте кластеризации волатильности, впервые систематически описанном Мандельбротом [3]. Классические тесты случайного блуждания — расширенный тест Дики–Фуллера,  $Q$ -статистика Льюнга–Бокса и тест отношения дисперсий [4] — как правило, не отвергают гипотезу единичного корня для уровня лог-цены и подтверждают близость доходностей к белому шуму по первому моменту.

Для биткоина эти стилизованные факты — тяжёлые хвосты распределения доходностей, кластеризация волатильности, асимметрия (эффект рычага) и нестационарность с структурными сдвигами — многократно подтверждены эмпирически. Их совокупность, с одной стороны, обосновывает трактовку цены как реализации случайного процесса, а с другой — объясняет, почему прогнозирование *уровня* цены обманчиво: тривиальный прогноз «завтра как сегодня» обеспечивает высокий коэффициент детерминации, не неся содержательной информации о направлении движения. Это наблюдение является ключевым мотивом перехода к постановке задачи в терминах направления, принятой в настоящей работе.

## 1.2 Глубокое обучение для прогнозирования временных рядов

Современная литература по прогнозированию финансовых и, в частности, криптовалютных временных рядов методами глубокого обучения обширна; в ней доминируют рекуррентные (LSTM, GRU), свёрточные и основанные на механизме внимания (трансформерные) архитектуры. Цзи, Ким и Им [5] сравнивают семейства глубоких моделей (полносвязные сети, LSTM, свёрточные и остаточные сети) для прогнозирования цены биткоина и приходят к практически важному выводу: при переходе от

регрессии уровня к *классификации* направления (рост/падение) классификационные модели оказываются полезнее для алгоритмической торговли, чем регрессионные. Ливьерис и соавторы [6] исследуют ансамбли глубоких моделей (LSTM, двунаправленные LSTM, свёрточные слои) на часовых данных криптовалют, рассматривая одновременно регрессионную и классификационную постановки и подчёркивая важность анализа автокорреляции ошибок прогноза.

Отдельное направление образуют работы, обогащающие ценовые признаки внешними источниками. Ким и соавторы [8] предлагают модель на основе самовнимания над несколькими LSTM-модулями (SAM-LSTM), использующую *on-chain* данные — характеристики сетевой активности блокчейна — наряду с ценовыми, и применяют детекцию точек смены режима для сегментации ряда. Орту и соавторы [7] рассматривают именно *классификацию направления* дневной цены биткоина и эфира, сопоставляя технические и социально-сетевые индикаторы; они сообщают рост точности с диапазона 51–55% (только технические признаки) до 67–84% при добавлении социальных индикаторов, что прямо указывает на ценность экзогенной информации и одновременно на скромный потолок предсказуемости по чисто техническим признакам. Дашаки и соавторы [9] развивают мультимодальный трансформерный подход с перекрёстным вниманием, объединяющий рыночные данные и доменно-специфический сентимент (на основе FinBERT) для прогноза тренда биткоина.

Обзорные и сравнительные исследования трансформерных и рекуррентных архитектур для криптовалют [10, 11] систематизируют это поле. Ву и соавторы [10] проводят обзор и эмпирическую оценку глубоких моделей для прогнозирования цен криптовалют, отмечая преимущество многомерных (многопризнаковых) подходов над одномерными и устойчивую конкурентоспособность свёрточно-рекуррентных архитектур. Лаббаф Ханики и Мантури [11] комбинируют трансформер (с эффективным механизмом внимания) и двунаправленную LSTM с техническими индикаторами на часовом и дневном горизонтах.

Из обзора видно, что: (i) доминируют глубокие нейросетевые архитектуры (рекуррентные, свёрточные, трансформерные), оцениваемые преимущественно на единичных разбиениях; (ii) классификация направления признаётся более релевантной торговле, чем регрессия уровня; (iii) экзогенные признаки (*on-chain*, сентимент, поток сделок) систематически улучшают качество. При этом честного по утечкам сравнения нейросетевых архитектур между собой и с сильными базовыми моделями, при разных *постановках* задачи и при последовательном контроле множественного тестирования в этих работах, как правило, не проводится; вопрос о том, оправдывает ли выразительная сила нейронных сетей их склонность к переобучению на высоковолатильных рядах с малым числом независимых наблюдений, остаётся открытым.

## 1.3 Классификация направления против регрессии уровней

Выбор между прогнозированием уровня и направления является не техническим, а концептуальным. Регрессия на уровень цены наследует свойства интегрированного процесса первого порядка: тривиальный персистентный прогноз достигает высокого  $R^2$ , который, однако, отражает лишь автокорреляцию уровней, а не способность предвидеть движение. Постановка в терминах направления (рост / падение / отсутствие значимого движения) не сводится к копированию последнего значения и непосредственно соответствует торговому решению. Результаты [5, 7] эмпирически поддерживают этот выбор: классификационные постановки оказываются практически полезнее. Введение третьего, нейтрального класса дополнительно отделяет вопрос «есть ли значимое движение» от вопроса «куда именно», что важно при доминировании интервалов без выраженного тренда.

## 1.4 Признаки: технические индикаторы, on-chain, деривативы и сентимент

Множество предикторов в литературе можно сгруппировать в четыре класса. *Технические индикаторы* (скользящие средние, индикаторы импульса и волатильности) описывают динамику самой цены и объёма; их применение повсеместно [5, 6, 11], однако предсказуемость по ним ограничена. *On-chain*-показатели — активность сети, число транзакций, характеристики предложения — специфичны для блокчейн-активов и, как показано в [8], несут дополнительный сигнал. *Деривативные* характеристики — ставка фондирования бессрочных фьючерсов и базис «фьючерс–спот» — отражают плечо, премию за риск и позиционирование участников. *Сентимент* — социально-сетевые индикаторы и индексы настроений — улучшает качество классификации направления [7, 9]. Существенно, что любой признак, чтобы быть допустимым предиктором, должен быть *каузальным* (использовать только информацию, доступную к моменту прогноза); нарушение этого условия — частый источник утечек данных.

## 1.5 Нестационарность, смена режимов и стилизованные факты

Цены биткоина прошли несколько отчётливых режимов — фазы взрывного роста, затяжные просадки, периоды штиля, — что проявляется в нестационарности уровня и лишь слабой стационарности доходностей. Кластеризация волатильности и тяжёлые хвосты [3] означают, что мгновенная волатильность сама является случайным, изменяющимся во времени процессом. Практическое следствие для прогнозирования направ-

ления двояко. Во-первых, модель, обученная в одном режиме, систематически теряет качество в другом, что требует адаптивных схем обучения и валидации. Во-вторых, поскольку предсказуема в первую очередь именно *волатильность* (а не знак доходности), потенциальный источник прогностической силы — обусловливание на состоянии волатильности, режиме и внутрисуточной сезонности, а не линейный прогноз доходности.

## 1.6 Методология валидации финансового машинного обучения и переобучение

Корректная оценка предсказательной модели на финансовых данных требует учёта зависимости и многобаровых, перекрывающихся меток. Лопес де Прадо [12] показывает, что обычная  $k$ -fold кросс-валидация переоценивает качество, поскольку перекрытие меток и rolling-признаков создаёт утечку между обучающей и тестовой выборками; в качестве решений предложены *purged k-fold* (с очисткой перекрывающихся меток и буфером-эмбарго) и *комбинаторная очищенная кросс-валидация* (CPCV), порождающая множество путей бэктеста. Для прогнозирования с разворачивающимся временем естественной является walk-forward (forward-chaining) схема, в которой обучающая выборка всегда строго предшествует тестовой; такую схему можно трактовать как симуляцию эксплуатации модели.

Множественное тестирование — перебор большого числа конфигураций — порождает риск отбора спурьёзно «хорошей» стратегии. Бэйли и Лопес де Прадо [13] вводят *Deflated Sharpe Ratio*, корректирующий оценку коэффициента Шарпа на число испытаний и ненормальность доходностей; Бэйли и соавторы [14] предлагают оценку *вероятности переобучения бэктеста* (РВО) через комбинаторно-симметричную кросс-валидацию. Тест Дибольда–Мариано [15] позволяет статистически сравнивать предсказательную точность двух моделей. Эти инструменты образуют каркас честной оценки, принятый в настоящей работе.

## 1.7 Метрики качества: коэффициент Мэтьюса и экономические критерии

При сильном дисбалансе классов доля верных ответов (ассигасу) вводит в заблуждение: тривиальный прогноз доминирующего класса достигает высокой точности, не неся информации. Коэффициент корреляции Мэтьюса (МСС) [16] — корреляция Пирсона на матрице ошибок — учитывает все её ячейки и в среднем информативнее точности и  $F_1$  при дисбалансе, поэтому используется как первичная метрика отбора. Наряду с классификационными метриками решающее значение имеет *экономическая* оценка: перевод прогнозов в торговый сигнал и расчёт прибыльности с учётом издержек (коэффициенты Шарпа, Сортино, Кальмара, максимальная просадка), а также

precision-at-coverage как торговой метрики качества решения. Окончательным арбитром значимости служит статистический контроль переобучения (DSR, PBO), описанный выше.

## 1.8 Выводы по главе и обоснование настоящей работы

Проведённый обзор позволяет выделить пробел в литературе. Несмотря на обилие нейросетевых моделей прогнозирования высоковолатильных рядов, (i) отсутствует честное по утечкам *like-for-like* сравнение нейросетевых архитектур (табличных и последовательностных) между собой и с сильными базовыми моделями при разных способах постановки трёхклассовой задачи направления; (ii) значимая часть результатов получена без строгого контроля утечек, нестационарности и множественного тестирования, что особенно опасно для моделей с большим числом параметров; (iii) зависимость дисбаланса классов от рыночного режима, как правило, не учитывается в определении целевой переменной. Настоящая работа закрывает этот пробел, оценивая нейросетевые модели в трёх постановках задачи на фоне сильных базлайнов, с режим-нормализованным вариантом метки и сквозным учётом переобучения. Формальная постановка задачи и методология излагаются в Главе 2.

## 2 Постановка задачи и методология

### 2.1 Формальная постановка трёхклассовой задачи

Пусть  $\{S_t\}$  — часовой ряд торгуемой цены закрытия BTC/USDT,  $H = 24$  — горизонт прогноза в часах,  $\theta$  — порог значимого движения. Доходность за горизонт в момент  $t$  определяется как  $\text{ret}_t = S_{t+H}/S_t - 1$ , а метка  $y_t \in \{-1, 0, +1\}$  — как

$$y_t = \begin{cases} +1, & \text{ret}_t \geq +\theta, \\ -1, & \text{ret}_t \leq -\theta, \\ 0, & \text{иначе,} \end{cases} \quad \theta = 2\%. \quad (2.1)$$

Содержательно модель отвечает не на вопрос «какой будет цена», а на вопрос «уйдёт ли цена за  $\pm 2\%$  вверх или вниз в течение суток или останется в коридоре». Порог  $\theta$  трактуется как *определение целевой переменной*, а не как настраиваемый гиперпараметр: его недопустимо подбирать под классификационную метрику, поскольку при разных порогах изменяются базовые частоты классов и сравнение метрик становится некорректным (форма скрытого подглядывания в разметку).

**Основная разметка и предыстория.** Приведённая выше формула задаёт направление по *конечной точке* горизонта (разметка *pointwise*); именно она использовалась в первоначальной версии работы. Однако при пороге  $\pm 2\%$  на суточном горизонте она порождает сильный перекося в нейтральный класс (около 70% наблюдений; у регим-нормализованного варианта — до 86%), на котором модели вырождаются в тривиальное «всегда флэт» и переобучаются на редких направленных исходах. Поэтому в качестве *основной* принята путь-зависимая разметка *triple-barrier* (раздел 2.3): она даёт сбалансированные классы, имеет более короткий средний срок удержания (меньше перекрытие меток и больше эффективно независимых наблюдений) и согласована с правилом выхода бэктеста, что структурно снижает переобучение. Pointwise и vol-scaled сохранены как альтернативные определения целевой переменной (абляции).

**Почему классификация, а не регрессия.** Как показано в Главе 1, регрессия на уровень цены вырождается в ловушку случайного блуждания. Постановка в терминах направления обходит эту ловушку и ближе к реальному торговому решению.

**Почему три класса.** Третий, нейтральный класс «флэт» вводится порогом и принципиально важен: большинство 24-часовых окон не сдвигаются на 2%, и требование направленной ставки там, где значимого движения нет, означает навязывание сигнала

в шуме. Флэт — это класс, в котором *не торгуют*; такая постановка честнее бинарной «вверх/вниз» и отделяет наличие движения от его направления.

## 2.2 Три постановки задачи

Все три постановки реализуют единый интерфейс: на входе — признаки (или каузальное окно для последовательностных моделей), на выходе — распределение по трём классам  $[P(-1), P(0), P(+1)]$ , прогноз — класс с максимальной вероятностью, а направленный балл уверенности определяется как  $\text{score} = P(+1) - P(-1)$ . Постановка — это *способ декомпозиции* задачи, не зависящий от конкретного обучателя; чтобы изолировать его влияние, обучатель внутри одного сравнения фиксируется. В центре внимания настоящей работы — нейросетевые обучатели (раздел 2.4); градиентный бустинг [17] используется как сильная базовая модель.

**Постановка А (мультиклассовый softmax).** Одна мультиклассовая модель напрямую оценивает  $[P(-1), P(0), P(+1)]$ .

**Постановка В (две независимые бинарные модели).** Обучаются две модели —  $p_{\text{up}} = \Pr[\text{ret} \geq +\theta]$  и  $p_{\text{dn}} = \Pr[\text{ret} \leq -\theta]$ , обе на всех данных; затем вероятности согласуются в три класса по зафиксированному до теста правилу

$$P(+1) \propto p_{\text{up}}(1 - p_{\text{dn}}), \quad P(-1) \propto (1 - p_{\text{up}})p_{\text{dn}}, \quad P(0) \propto (1 - p_{\text{up}})(1 - p_{\text{dn}}) + p_{\text{up}}p_{\text{dn}},$$

с последующей нормировкой. Для каждой стороны (long/short) допускаются отдельные пороги уверенности.

**Постановка С (каскад «гейт → направление»).** Сначала «гейт» оценивает вероятность значимого движения  $p_{\text{big}} = \Pr[|\text{ret}| \geq \theta]$ , затем модель направления различает рост и падение; итоговые вероятности —  $P(+1) = p_{\text{big}} p_{\text{up}}$ ,  $P(-1) = p_{\text{big}}(1 - p_{\text{up}})$ ,  $P(0) = 1 - p_{\text{big}}$ . Рассматриваются два варианта обучения модели направления: *c1* — на реальной популяции крупных движений ( $|\text{ret}| \geq \theta$ ); и *c2* — на популяции, отобранной/взвешенной по предсказанию гейта (с демонстрацией смещения отбора, selection bias). Чтобы вариант *c2* оставался корректной демонстрацией, веса гейта оцениваются вне обучающей подвыборки (out-of-fold).

**Исследовательский вопрос** формулируется так: влияет ли сам способ декомпозиции (совместная softmax-голова против независимых бинарных моделей против каскада) на качество прогноза и экономику, если все прочие элементы конвейера зафиксированы?



## 2.3 Типы целевой переменной

Помимо способа моделирования, рассматриваются три *определения* целевой переменной, каждое из которых является отдельным сквозным экспериментом и сравнивается по экономике, а не по классификационным метрикам (различные базовые частоты делают их несопоставимыми). *Основной* в настоящей работе принята разметка triple-barrier; pointwise и vol-scaled опробованы первоначально и оставлены как альтернативы (абляции).

- **Triple-barrier (основная разметка).** Путь-зависимая разметка: от уровня  $S_t$  строятся верхний  $(+\theta)$  и нижний  $(-\theta)$  барьеры и вертикальный барьер на горизонте  $H$ ; метка определяется тем, какой барьер достигнут *первым* (по внутрибаровым максимумам/минимумам), а выход — в момент касания (стоп/тейк). Эта разметка выбрана основной по трём причинам: (i) *баланс классов* (порядка 30/43/27 против  $\approx 15/70/15$  у pointwise), не дающий модели вырождаться в «всегда флэт»; (ii) *более короткий средний срок удержания* (выход по первому касанию, а не фиксированные  $H$  баров) — меньше перекрытие меток, выше средняя уникальность и больше эффективно независимых наблюдений; (iii) согласованность с правилом выхода бэктеста (метка отвечает реализуемой сделке со стоп-лоссом/тейк-профитом). Все три свойства напрямую снижают переобучение на ряде с малым числом независимых наблюдений, поэтому именно triple-barrier используется как основной таргет и для бустинга, и для нейросетей.
- **Pointwise (point-to-point; первоначальная разметка).** Метка определяется по конечной точке:  $\text{ret}_t = S_{t+H}/S_t - 1$  с фиксированным порогом  $\pm\theta$ ; правило выхода в бэктесте — удержание горизонта  $H$ . Использовалась изначально, но при  $\theta = 2\%$  даёт около 70% нейтрального класса, на котором модели схлопываются и переобучаются; оставлена как альтернативная постановка/абляция.
- **Vol-scaled (режим-нормализованный).** Порог адаптируется к текущей каузально оценённой волатильности:  $\theta_t = k \sigma_t$ , где  $\sigma_t$  — экспоненциально сглаженная волатильность доходностей со сдвигом на один бар (без заглядывания вперёд), масштабированная множителем  $\sqrt{H}$ ; параметр  $k$  перебирается по небольшому предварительно зарегистрированному набору. Корректирует зависимость дисбаланса от режима волатильности, однако при  $k = 1.5$  перекося в нейтральный класс ещё сильнее (до 86%), поэтому также используется лишь как абляция.

Порог метки согласуется с правилом выхода: triple-barrier — стоп/тейк по барьеру; point-to-point — удержание  $H$ .

## 2.4 Нейросетевые модели и базовые модели сравнения

Центральный объект изучения — *нейросетевые модели* в двух представлениях данных.

**Табличный многослойный перцептрон (MLP).** Полносвязная сеть на тех же инженерных признаках, что и базовые модели (apples-to-apples сравнение): 1–2 скрытых слоя, нормировка батча, dropout; на выходе — softmax по трём классам. Предобработка (импутация пропусков медианой, стандартизация) обучается строго на train-фолде.

**Последовательностные модели (GRU, LSTM, причинный TCN).** Работают на строго каузальных окнах  $[t - L + 1, \dots, t]$  исходных каналов (лог-доходности, лог-объём, несколько нормированных индикаторов), организованных в тензор формы  $(L, C)$ . Для свёрточной сети используется *причинная* (causal) свёртка, исключая заглядывание вперёд; рекуррентные сети берут последнее скрытое состояние. Это позволяет нейросети извлекать временные паттерны сверх hand-engineered лагов.

**Обучение и регуляризация.** Кросс-энтропия (или focal loss) с весами семплов (класс  $\times$  уникальность  $\times$  давность); оптимизатор AdamW с весовым затуханием; ранняя остановка по MCC на отложенном purged-валидационном срезе; агрессивная регуляризация (малые сети, dropout, weight decay) — ввиду дефицита эффективно-независимых наблюдений. Нейросетевая часть выполняется в отдельном процессе (во избежание конфликтов рантаймов с базовыми библиотеками) и при наличии — на графическом ускорителе.

**Базовые модели (baselines).** В качестве сильных базовых моделей используется градиентный бустинг над решающими деревьями — LightGBM [17] (основная), а также XGBoost [18] и CatBoost [19]: они эффективны на табличных данных указанного масштаба, нативно работают с пропусками и детерминированы. Честное сопоставление нейросетей с этими базлайнами на одних и тех же purged-фолдах является ядром работы. При этом, как отмечается в литературе [5, 10] и согласуется с оценкой эффективного числа независимых наблюдений (непересекающихся 24-часовых меток), на табличных данных такого масштаба сильные базлайны часто оказываются конкурентоспособными, а нейросетевые модели склонны к переобучению; последовательностные архитектуры — наиболее перспективная для нейросетей ниша, особенно на больших объёмах данных.

## 2.5 Валидация: purged + embargoed walk-forward как операционная петля

Основным, deploy-честным методом отбора и оценки является *purged + embargoed walk-forward* (forward-chaining): обучающая выборка всегда строго предшествует тесто-

вой; перед каждым тестовым блоком из обучения удаляются бары, чьи 24-часовые метки перекрываются с тестовым блоком (purge), и добавляется буфер-эмбарго, устраняющий утечку через автокорреляцию. Строгий контроль границы требует выполнения условия  $\max(\text{train}) + H < \min(\text{test})$ , исключающего касание меткой последнего обучающего бара тестового периода. Такая схема трактуется как *операционная петля*: каждый шаг — «переобучились на окне  $\rightarrow$  предсказали следующий период  $\rightarrow$  сдвинулись вперёд», то есть петля валидации совпадает с петлёй эксплуатации. Для учёта нестационарности предусмотрены адаптационные настройки (расширяющееся или скользящее окно, взвешивание по давности, периодичность переобучения), рассматриваемые как абляции, а не как настраиваемые в оптимизации параметры.

В качестве *вторичной* оценки робастности используется комбинаторная очищенная кросс-валидация (CPCV), порождающая множество путей бэктеста и служащая основой для оценки вероятности переобучения; при этом учитывается, что CPCV обучает в том числе на пост-тестовых данных и потому является менее deploy-честной. Предобработка (шкалирование, кодирование, импутация) выполняется строго внутри обучающего фолда, чтобы исключить утечку.

## 2.6 Метрики, статистическая значимость и экономическая оценка

Обучение моделей ведётся по логарифмической функции потерь; *отбор и отчёт* — по коэффициенту Мэтьюса (как первичной метрике, устойчивой к дисбалансу), а также по  $\text{masro-}F_1$ , полноте по классам, матрице ошибок и калибровочным метрикам; точность (ассигасу) как целевая не используется. Подбор гиперпараметров проводится методом байесовской оптимизации на purged walk-forward (не случайным поиском и не обычным  $k$ -fold), с отбором по среднему MCC по фолдам.

Прибыльность оценивается *экономическим бэктестом* с явными допущениями: сигнал формируется на закрытии бара  $t$ , вход осуществляется по цене открытия следующего бара  $t+1$  (а не по тому же закрытию), удержание — на горизонт (или по барьеру для triple-barrier); допускается короткая позиция, размер позиции фиксирован; издержки задаются в базисных пунктах. Чтобы оценка не зависела от произвольной фазы входа, метрики усредняются по всем фазовым сдвигам входа, а коэффициент Шарпа считается на де-перекрытых по-сделочных доходностях с аннуализацией по числу *сделок*, а не баров. Обязательным является сравнение с пассивной стратегией «купи и держи». Статистическая значимость контролируется через Probabilistic и Deflated Sharpe Ratio [13], вероятность переобучения бэктеста [14] и тест Дибольда–Мариано [15] между постановками, причём в число испытаний для DSR включается *весь* фактически перебранный грид конфигураций.

## 3 Данные и признаки

### 3.1 Базовый ценовой ряд

В качестве базового ряда используются часовые свечи OHLCV пары BTC/USDT, полученные с биржи Binance, за весь доступный непрерывный период — ориентировочно с августа 2017 г. по июнь 2026 г. (около  $7.7 \cdot 10^4$  баров,  $\approx 8.8$  года). Выбор обоснован следующим. Во-первых, это наиболее длинная непрерывная история по биткоину, необходимая для устойчивой валидации по множеству рыночных режимов. Во-вторых, используется именно *торгуемая* цена (а не взвешенная комбинация OHLC), поскольку на ней же строится экономический бэктест, — чтобы сигнал и исполнение находились в единой системе координат. В-третьих, переиспользуется уже имеющийся загрузчик данных без введения новой зависимости, что обеспечивает консистентность слоя данных. Дата отсечки фиксируется заранее (а не привязывается к текущему моменту) ради воспроизводимости; сырой снимок данных сохраняется вместе с контрольной суммой и числом строк.

Пропуски в истории немногочисленны (порядка  $10^2$  баров, ранние сбои API); они обрабатываются реиндексацией на полную часовую сетку с явной пометкой гэпа, чтобы доходность не вычислялась «через дыру» за интервал, больший одного бара.

### 3.2 Экзогенные данные: крипто-нативные, а не макроэкономические

Экзогенный набор по умолчанию — крипто-нативный, обладающий длинной историей и не требующий платных ключей доступа:

- **Деривативы:** ставка фондирования (funding) бессрочных фьючерсов и базис «фьючерс–спот» — индикаторы плеча, премии за риск и позиционирования;
- **Поток сделок (order-flow):** дисбаланс агрессивных покупок и продаж и его производные, вычисляемые из объёмов тейкер-покупок и доступные на всю историю;
- **On-chain:** дневные показатели сетевой активности (активные адреса, число транзакций, хешрейт, характеристики предложения), мотивированные результатами [8];
- **Сентимент:** индекс «страха и жадности» (Fear & Greed).

Кросс-активы с традиционных рынков (фондовые индексы, валюты, металлы) сознательно *не* включены в базовую модель: их часовая история ограничена примерно 729 днями, и их добавление схлопнуло бы обучающее окно для всех признаков примерно до двух лет, пожертвовав длинной историей; к тому же на часовом масштабе они

«протухают» вне биржевых сессий, тогда как криптовалюта торгуется непрерывно. Поэтому кросс-активы оставлены опциональной *абляцией* на коротком окне. Открытый интерес (open interest) исключён из длинных признаков ввиду крайне ограниченной бесплатной истории.

### 3.3 Проектирование признаков

Все признаки строго трейлинговые (каузальные) — используют только информацию, доступную к моменту прогноза. Набор включает:

- логарифмические доходности и их лаги на наборе горизонтов  $\{1, 2, 3, 6, 12, 24, 48, 72, 168\}$ ;
- rolling-волатильность на окнах  $\{24, 72, 168\}$  и её отношения (терм-структуру волатильности);
- *нормированные* технические индикаторы — гистограмму MACD (а не сырую линию, дрейфующую со шкалой цены), отношение ATR к цене, z-оценку изменения OBV;
- логарифм объёма и его изменения/z-оценки; скользящие средние в форме отношений  $\text{close}/\text{MA} - 1$ ;
- календарные признаки в форме синус/косинус (час, день недели, месяц);
- **режим/сезонные** признаки: диурнальную климатологию волатильности (типичную абсолютную доходность для данного сочетания «час × день недели», вычисляемую каузально), ранг и z-оценку текущей волатильности относительно недавней истории, просадку от трейлинг-максимума, длинный тренд и 30-дневную волатильность.

Экзогенные признаки лагируются у источника (значение в строке  $t$  отражает состояние, известное строго до  $t$ ); дневные on-chain показатели сдвигаются не менее чем на публикационную задержку до приведения к часовой сетке. Метка *не* кэшируется, а строится «на лету» из закэшированных признаков и OHLC, что делает смену типа целевой переменной мгновенной.

Для последовательностных нейросетей те же каузальные каналы организуются в скользящие окна  $[t - L + 1, \dots, t]$  длины  $L$  (тензор формы  $(L, C)$ ): окно содержит только прошлое, поэтому не вносит утечки метки, а первые  $L - 1$  баров каждого фолда, не имеющие полного окна, отбрасываются. Табличные модели (бустинг, MLP) используют те же признаки в плоском виде.

### 3.4 Пропуски, структурное отсутствие и воспроизводимость

Часть экзогенных признаков существует не на всей истории: ставка фондирования и базис появляются лишь с запуска бессрочных фьючерсов (сентябрь 2019 г.),

а спот — с августа 2017 г.; отсюда значительная доля пропусков одним непрерывным куском в ранней эпохе (аналогично индексу настроений с начала 2018 г.). Это *структурное* отсутствие информативно и потому не устраняется удалением: деревья принимают пропуски нативно и кодируют «до-перп»-эпоху отдельной ветвью. Для моделей, не допускающих пропусков (нейросети, логистическая регрессия), вводятся бинарные флаги наличия соответствующих рядов, а влияние деривативных признаков оценивается *абляцией* (с/без funding и базиса), а не слепым удалением. Для всех признаков, содержащих rolling- и сезонные статистики, проводится отдельная проверка каузальности.

## 4 Дизайн экспериментов

### 4.1 Принципиальный эксперимент: нейросети против базлайнов

Главный эксперимент — честное сравнение *нейросетевых архитектур* (табличного MLP и последовательностных GRU/LSTM/TCN) с сильными базовыми моделями (LightGBM, XGBoost, CatBoost) на основной конфигурации, на *одних и тех же* purged-фолдах walk-forward. Все обучатели реализуют единый интерфейс и оцениваются через один и тот же модуль метрик; нейросетевая часть выполняется в отдельном процессе. Принципиально, что *автоматические тесты утечки* применяются и к нейросетям (вставка метки как фичи → метрики близки к идеалу; перемешивание таргета → падение до baseline; сдвиг признаков на горизонт вперёд → рост), а фолды нейросетевого субпроцесса побитово совпадают с фолдами базлайнов. Это позволяет ответить на центральный вопрос работы: оправдывает ли выразительность нейронных сетей их склонность к переобучению на высоковолатильном ряде с малым числом независимых наблюдений.

### 4.2 Рамка постановок и абляции

Принципиальный эксперимент встроен в рамку, фиксирующую влияние постановки задачи и определения целевой переменной: небольшой пред-зарегистрированный грид сквозных экспериментов по оси *типа целевой переменной* (triple-barrier как основной, а также point-to-point и режим-нормализованный vol-scaled с несколькими значениями  $k$ ), внутри каждого из которых сравниваются три постановки (А, В, С, причём С в двух вариантах c1/c2) на фиксированном обучателе, признаках, фолдах и пороге. *Основным* (headline) выбран эксперимент с разметкой triple-barrier: именно на нём выполняется полный набор углублённых анализов — сравнение обучателей, *включая нейросетевые модели*, и абляции, — тогда как остальные типы целевой переменной несут лишь базовое сравнение постановок А/В/С. Число конфигураций *сознательно ограничено*: каждый дополнительный эксперимент повышает планку статистической значимости (через число испытаний в DSR и в оценке вероятности переобучения). Дополнительно предусмотрены абляции: режим окна (расширяющееся против скользящего) и взвешивание по давности — для оценки чувствительности к нестационарности; вклад деривативных признаков (с/без funding и базиса); вклад кросс-активов на коротком окне. Диагностика переобучения включает сопоставление качества на обучении и вне выборки, важность признаков методом перестановок и значения Шепли, а также мониторинг распада эджа и дрейфа распределений (PSI/KS) по ходу walk-forward. Фик-

сированные пороги, отличные от основного 2%, заведены как механизм, но их полный экономический свип отнесён к направлениям дальнейшей работы.

### 4.3 Оборудование и воспроизводимость

Поскольку набор данных невелик, основная вычислительная нагрузка — это *CPU-параллельная* задача пропускной способности (множество мелких независимых обучений), а не GPU-задача; графический ускоритель необходим лишь нейросетевым моделям. Для эффективного использования ресурсов вводится единый тред-бюджет (произведение числа параллельных обучений на число потоков одного обучения не превышает числа физических ядер), нейросетевая часть выносится в отдельный процесс, а параллельный подбор гиперпараметров используется для ускорения при сохранении детерминизма финальной переоценки через зафиксированные наилучшие параметры. Полная воспроизводимость обеспечивается фиксацией всех источников случайности, фиксированной датой отсечки данных и сохранением сырого снимка с контрольной суммой.

### 4.4 Результаты

*[Результаты будут добавлены после полного вычислительного прогона.]*

В данном разделе будут приведены: таблица сравнения *нейросетевых архитектур* (MLP, GRU, LSTM, TCN) с базовыми моделями (LightGBM, XGBoost, CatBoost) на идентичных фолдах; сводная таблица сравнения постановок А/В/С по классификационным (MCC,  $\text{macro-}F_1$ , полнота по классам  $\pm 1$ ), сигнальным (информационный коэффициент и его стабильность) и экономическим (коэффициент Шарпа, Deflated Sharpe Ratio) метрикам; распределения метрик по фолдам (диаграммы размаха) вместо одиночных чисел; наложенные кривые precision-at-coverage; результаты теста Дибольда–Мариано между моделями и постановками; результаты абляций; а также итоги статистического контроля переобучения (DSR, PBO) по всему гриду. Никакие числовые результаты до завершения прогона не приводятся.



## Заключение

*[Будет написано по результатам исследования.]*

В заключении предполагается обобщить итоги сравнения трёх постановок задачи прогнозирования направления цены биткоина, сформулировать выводы относительно границ предсказуемости направления на часовом горизонте, соотнести полученные результаты с поставленными задачами и наметить направления дальнейшей работы (явная модель режима на основе скрытой марковской модели; полный экономический свип порога и типа целевой переменной; последовательностные модели на большем объёме данных; обогащение экономического слоя моделью размера позиции и издержек; кросс-биржевая и мультиактивная проверка обобщаемости; живая (forward) валидация).

## Литература

- [1] Nakamoto S. Bitcoin: A Peer-to-Peer Electronic Cash System. 2008. URL: <https://bitcoin.org/bitcoin.pdf>.
- [2] Fama E. F. Efficient Capital Markets: A Review of Theory and Empirical Work // The Journal of Finance. 1970. Vol. 25, no. 2. P. 383–417.
- [3] Mandelbrot B. The Variation of Certain Speculative Prices // The Journal of Business. 1963. Vol. 36, no. 4. P. 394–419.
- [4] Lo A. W., MacKinlay A. C. Stock Market Prices Do Not Follow Random Walks: Evidence from a Simple Specification Test // The Review of Financial Studies. 1988. Vol. 1, no. 1. P. 41–66.
- [5] Ji S., Kim J., Im H. A Comparative Study of Bitcoin Price Prediction Using Deep Learning // Mathematics. 2019. Vol. 7, no. 10. Art. 898. DOI: 10.3390/math7100898.
- [6] Livieris I. E., Pintelas E., Stavroyiannis S., Pintelas P. Ensemble Deep Learning Models for Forecasting Cryptocurrency Time-Series // Algorithms. 2020. Vol. 13, no. 5. Art. 121. DOI: 10.3390/a13050121.
- [7] Ortu M., Uras N., Conversano C., Bartolucci S., Destefanis G. On Technical Trading and Social Media Indicators for Cryptocurrency Price Classification through Deep Learning // Expert Systems with Applications. 2022. Vol. 198. Art. 116804. DOI: 10.1016/j.eswa.2022.116804.
- [8] Kim G., Shin D.-H., Choi J. G., Lim S. A Deep Learning-Based Cryptocurrency Price Prediction Model That Uses On-Chain Data // IEEE Access. 2022. Vol. 10. P. 56232–56248. DOI: 10.1109/ACCESS.2022.3177888.
- [9] Mohammadi Dashtaki S., Hosseini Chagahi M., Bahadori A., Moshiri B., Piran M. J., Montazeri A. HSIF: A Transformer-Based Cross-Attention Framework for Cryptocurrency Trend Forecasting via Multimodal Sentiment–Market Fusion // IEEE Access. 2025. Vol. 13. DOI: 10.1109/ACCESS.2025.3605522.
- [10] Wu J., Zhang X., Huang F., Zhou H., Chandra R. Review of Deep Learning Models for Crypto Price Prediction: Implementation and Evaluation. 2024. arXiv:2405.11431. URL: <https://arxiv.org/abs/2405.11431>.
- [11] Labbaf Khaniki M. A., Manthouri M. Enhancing Price Prediction in Cryptocurrency Using Transformer Neural Network and Technical Indicators. 2024. arXiv:2403.03606. URL: <https://arxiv.org/abs/2403.03606>.

- [12] López de Prado M. *Advances in Financial Machine Learning*. Hoboken, NJ: John Wiley & Sons, 2018.
- [13] Bailey D. H., López de Prado M. The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality // *The Journal of Portfolio Management*. 2014. Vol. 40, no. 5. P. 94–107.
- [14] Bailey D. H., Borwein J., López de Prado M., Zhu Q. J. The Probability of Backtest Overfitting // *Journal of Computational Finance*. 2017. Vol. 20, no. 4. P. 39–69.
- [15] Diebold F. X., Mariano R. S. Comparing Predictive Accuracy // *Journal of Business & Economic Statistics*. 1995. Vol. 13, no. 3. P. 253–263.
- [16] Matthews B. W. Comparison of the Predicted and Observed Secondary Structure of T4 Phage Lysozyme // *Biochimica et Biophysica Acta (BBA) — Protein Structure*. 1975. Vol. 405, no. 2. P. 442–451.
- [17] Ke G., Meng Q., Finley T., Wang T., Chen W., Ma W., Ye Q., Liu T.-Y. LightGBM: A Highly Efficient Gradient Boosting Decision Tree // *Advances in Neural Information Processing Systems (NeurIPS)*. 2017. Vol. 30. P. 3146–3154.
- [18] Chen T., Guestrin C. XGBoost: A Scalable Tree Boosting System // *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016. P. 785–794.
- [19] Prokhorenkova L., Gusev G., Vorobev A., Dorogush A. V., Gulin A. CatBoost: Unbiased Boosting with Categorical Features // *Advances in Neural Information Processing Systems (NeurIPS)*. 2018. Vol. 31. P. 6638–6648.