



НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ

«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук | Образовательная программа «Анализ больших данных»

Прогнозирование валового регионального продукта (ВРП) субъектов Российской Федерации с помощью ансамблевых методов машинного обучения

Выполнил: Семенюченко Артём Геннадьевич, студент ФКН НИУ ВШЭ

Науч. руководитель: Паточенко Евгений Анатольевич, ст. преп. ФКН НИУ ВШЭ

Структура доклада

1. Актуальность и цель исследования
2. Данные и методология
3. Результаты экспериментов
4. SHAP-интерпретация
5. Заключение

Почему прогнозирование ВРП регионов?

- ▼ ВРП — ключевой индикатор развития 85 субъектов РФ
- ▼ **Территориальная неоднородность:** сырьевые, индустриальные, аграрные, бюджетно-зависимые регионы
- ▼ **Лаг публикации** Росстата — бюджетное планирование требует оперативных оценок до выхода официальных данных

Вызовы задачи

- ▼ Панельная структура: (регион, год)
- ▼ Временная зависимость + межрегиональная неоднородность
- ▼ Риск утечки данных (*leakage*)
- ▼ Структурные разрывы: 2008–09, 2014–15, 2020, 2022–23
- ▼ Малая панель (≈ 20 набл./регион)

Цель: воспроизводимый pipeline прогнозирования ВРП на основе ML с корректной out-of-sample валидацией и явным контролем leakage

Цель и задачи исследования

Цель работы

Разработка и оценка воспроизводимого пайплайна прогнозирования ВРП субъектов РФ на панельных временных данных с использованием эконометрических базовых моделей и ансамблевых методов машинного обучения.

Ключевые задачи:

1. Сформировать панельную базу данных за **2005–2024 гг.** (Росстат, ЕМИСС, Банк России, Минэкономразвития, Казначейство)
2. Построить **базовые** (наивный, AR(1), Ridge с FE) и **ансамблевые** модели (LightGBM, CatBoost, GPBoost, EmbMLP)
3. Реализовать leakage-free **expanding-window** кросс-валидацию (тестовый период: 2015–2023)
4. Провести **ablation study** по блокам признаков и **robustness checks** (выбросы и кризисные периоды)
5. Построить **SHAP-интерпретацию** лучшей одиночной модели и сформировать взвешенный ансамбль

Данные и признаковое пространство

Эмпирическая база:

- ▼ 85 субъектов РФ, **2005–2024 гг.**
- ▼ Целевая переменная: $\Delta \log \text{ВРП}_{i,t} = \log \text{ВРП}_{i,t} - \log \text{ВРП}_{i,t-1}$
- ▼ Горизонт прогноза: $h = 1$ (один год вперёд)

Предобработка:

- ▼ Дефлирование ИПЦ (денежные показатели)
- ▼ `RobustScaler` — квартильная нормировка, устойчивость к выбросам (Москва, ХМАО, ЯНАО)
- ▼ Все операции — **только на Train_k** каждого $\text{fold}'a$


Блоки признаков:

$$X_{i,t} = [X^{\text{lag}}, X^{\text{prod}}, X^{\text{inv}}, X^{\text{lab}}, X^{\text{bud}}, X^{\text{macro}}, X^{\text{price}}, X^{\text{shock}}, X^{\text{cat}}]$$

Блок	Содержание
lag	Лаги ВРП, скользящие средние
prod	Пром-сть, с/х, стр-во, торговля
inv	Инвестиции в осн. капитал
lab	Занятость, зарплата, доходы
bud	Доходы/расходы бюджета
macro	Ключевая ставка, кредиты
price	USD/RUB волат., прод. корзина
shock	Dummies кризисов (2009, 2015, 2020)
cat	Тип региона, фед. округ

Методология: expanding-window валидация и метрики

Схема расширяющегося окна (9 fold'ов):



Начальное окно: 2005–2014 (≥ 10 лет).

Гиперпараметры — Optuna (60 trials, только на Train_k).

Постановка задачи:

$$\hat{y}_{i,t+1} = f_{\theta}(X_{i,t}^{\text{available}})$$

$$y_{i,t} = \Delta \log(\text{GRP}_{i,t}^{\text{real}})$$

Метрики качества:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_j (y_j - \hat{y}_j)^2}$$

$$\text{MAE} = \frac{1}{n} \sum_j |y_j - \hat{y}_j|$$

$$R_{\text{OOS}}^2 = 1 - \frac{\sum_j (y_j - \hat{y}_j)^2}{\sum_j (y_j - \hat{y}_j^{\text{bench}})^2}$$

$R_{\text{OOS}}^2 > 0$ — превосходство над наивным прогнозом.

Базовые модели

- ▼ **Наивный:** $\hat{y}_{i,t+1} = y_{i,t}$
- ▼ **AR(1):** $y_{i,t+1} = \alpha_i + \rho_i y_{i,t} + \varepsilon$ (по каждому региону)
- ▼ **Ridge с FE:** L2-регрессия с индивидуальными и временными фиксированными эффектами

Взвешенный ансамбль

$$\hat{y}^{\text{ens}} = w \hat{y}^{\text{CB}} + (1 - w) \hat{y}^{\text{LGB}}$$


Перебор $w \in [0,00; 1,00]$, шаг 0,05, min pooled RMSE

Оптимум: $w^* = 0,25 \Rightarrow \text{CB} \times 0,25 + \text{LGB} \times 0,75$

Ансамблевые алгоритмы ML

- ▼ **LightGBM:** градиентный бустинг, leaf-wise рост, EFB
- ▼ **CatBoost:** ordered boosting, симметричные деревья, устойчивость к кат. признакам
- ▼ **GPBoost:** бустинг + случайные эффекты регионов
 $y_{i,t} = F(X_{i,t}) + b_i + \varepsilon_{i,t}, \quad b_i \sim \mathcal{N}(0, \sigma_b^2)$
- ▼ **EmbMLP:** нейросеть с обучаемыми эмбедингами регионов

Взвешенный ансамбль: поиск оптимального веса



Процедура post-hoc оптимизации:

- ▼ После независимой CV каждой подмодели
- ▼ Перебор $w \in \{0,00; 0,05; \dots; 1,00\}$
- ▼ Минимизация pooled RMSE на hold-out 9 fold'ов
- ▼ Leakage исключён — Training target не задействуется

Результат

$w^* = 0,25$; $\text{RMSE}(w^*) = 0,0382$

LightGBM вносит бо́льший вклад (доля 0.75).

Сравнение моделей: сводная таблица метрик


model	RMSE	MAE	OOS_R2
Ensemble(CB×0.25+LGB×0.75)	0.0382 +/- 0.0129	0.0288 +/- 0.0113	0.1440 +/- 0.3071
LGBMForecaster	0.0388 +/- 0.0121	0.0295 +/- 0.0105	0.1219 +/- 0.2629
CatBoostForecaster	0.0408 +/- 0.0153	0.0311 +/- 0.0135	0.0356 +/- 0.3884
NaiveForecaster	0.0419 +/- 0.0117	0.0331 +/- 0.0104	0.0000 +/- 0.0000
AR1Forecaster	0.0487 +/- 0.0216	0.0336 +/- 0.0120	-0.4036 +/- 0.8911
EmbMLPForecaster	0.0491 +/- 0.0199	0.0378 +/- 0.0166	-0.4386 +/- 0.9218
RidgeFEForecaster	0.0517 +/- 0.0261	0.0419 +/- 0.0273	-0.6176 +/- 1.0868
GPBoostForecaster	0.4882 +/- 0.5955	0.4285 +/- 0.5568	-280.9273 +/- 515.5155

Ключевые итоги

- ▼ **Лучшая:** ансамбль CB×0,25+LGB×0,75
RMSE = **0,0382**, снижение **8,8%** vs наивный; $R_{OOS}^2 = 0,144 > 0$
- ▼ **LightGBM:** RMSE = 0,0388, лучшая одиночная
- ▼ **CatBoost:** RMSE = 0,0408
- ▼ AR(1), EmbMLP, Ridge --- уступают наивному
- ▼ **GPBoost:** нестабилен (OOS отключает GP)

MAPE = **2,88%**; MAE = 6,24 млрд руб.
(vs 7,25 наивный)

RMSE прогнозов: тестовые годы 2015–2023




Обучающий период (2006–2014):

Ср. рост ВРП: 4,2%/год; макс. 9,7% (2007);
мин. -4,5% (2009)

Тестовый период (2015–2023):

Ансамбль $CB+LGB$ сохраняет **наименьший RMSE** во все кризисные годы (2020, 2022–23)

Ablation study: вклад блоков признаков (LightGBM)



Сценарии последовательного добавления:

Сценарий	Состав
A0	Только лаги ВРП
A1	A0 + производственный блок
A2	A1 + инвестиц. + трудовой + бюджетный
A3	A2 + макро + цены + кат. + кризисные


Вывод

Наибольший прирост: A0→A1 (производственный блок), RMSE: 0,044 → 0,043. A2 и A3 ≈ A1.

Анализ устойчивости (Robustness Checks)

RC1 — без регионов-выбросов


Исключены: Москва, ХМАО, ЯНАО, Сахалинская обл.



⇒ Ансамбль сохраняет лидерство; LightGBM опережает CatBoost — ранжирование устойчиво


RC2 — кризисные vs нормальные годы

Кризисные fold'ы: 2008–09, 2014–15, 2020, 2022–23



⇒ Ансамбль лучший в обеих подгруппах. Бустинг устойчив в кризисные периоды (Lashina & Grishunin, 2023)

SHAP-интерпретация: глобальный анализ (LightGBM)




Топ-5 признаков по $|\overline{\phi_j}|$:

1. `usd_rub_volatility_lag1`
волатильность USD/RUB; вклад в 2 раза выше след.
2. `min_food_basket_cost_lag1`
стоимость минимального набора продуктов
3. `policy_rate_lag1`
номинальная ключевая ставка ЦБ РФ
4. `policy_rate_real_lag1`
реальная ключевая ставка
5. `paid_services_to_grp_lag1`
доля платных услуг в ВРП

Ключевой вывод

Монетарные переменные
доминируют; USD/RUB — главный
фактор риска.

SHAP: вклад блоков признаков по типам регионов



Интерпретация по блокам:


Блок	Вклад	Вывод
macro	0,21–0,27	Лидер везде
price	0,16–0,21	2-й везде
prod	0,17 (сырьев.)	Важен для добычи
inv	0,11–0,16	Выше у сервисных
cat	≈ 0	Нулевой вклад
lag	0,09–0,10	Низкая автокорр.

Вывод

Все типы регионов однородно реагируют на монетарные шоки ДКП ЦБ РФ.

Анализ ошибок и тест Дибольда–Мариано

Тепловая карта ошибок (MAE, регион × год)



Наибольшие ошибки --- регионы с нестационарной структурой эк-ки (Ненецкий АО

Тест Дибольда–Мариано (DM)

H_0 : обе модели одинаково точны

$$d_t = e_{1,t}^2 - e_{2,t}^2; \quad DM = \bar{d} / SE(\bar{d})$$

Сравнение	DM	$p_{дв}$	$p_{одн}$
CatBoost vs Наивный	0,046	0,963	0,482
LightGBM vs Наивный	6,247	< 0,001	< 0,001

Вывод

LightGBM **статистически достоверно** превосходит наивный прогноз ($\alpha = 0,001$, $DM = 6,247$).

CatBoost --- выигрыш в RMSE есть, но не значим.

Ансамбль наследует значимость от LGB (доля 0,75).

Заключение: основные результаты

Главный результат

Ансамбль CB×0,25 + LGB×0,75 превзошёл все 8 моделей:

- ▼ RMSE = **0,0382** --- снижение **8,8%** vs наивный (0,0419)
- ▼ $R^2_{\text{OOS}} = 0,144 > 0$ --- устойчивое превосходство OOS
- ▼ **MAPE** = 2,88%, MAE = 6,24 млрд руб.
- ▼ DM = 6,247, $p < 0,001$ (от LGB-компоненты, доля 0,75)

SHAP: монетарные переменные **доминируют**; ДКП ЦБ РФ однородна по регионам.

Дополнительные выводы:

- ▼ Ablation: наибольший прирост --- производственный блок (A0→A1)
- ▼ Robustness checks подтвердили устойчивость ранжирования
- ▼ GPBoost нестабилен OOS --- GP-компонента отключается

Ограничения:

- ▼ Малая панель (≈ 20 набл./регион)
- ▼ Часть данных доступна с лагом публикации
- ▼ SHAP объясняет, но *не доказывает* причинность

Практ. значимость: nowcast ВРП регионов до публикации Росстата.



Спасибо за внимание!

Автор: Семенюченко Артём Геннадьевич

Науч. руководитель: Паточенко Евгений Анатольевич

Тема: Прогнозирование ВРП субъектов РФ
ансамблевыми методами машинного обучения

Лучшая модель: $CB \times 0,25 + LGB \times 0,75$
RMSE = 0,0382 **MAPE** = 2,88% $R^2_{OOS} = 0,144$