

Федеральное государственное автономное образовательное учреждение
высшего образования

**НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»**

Факультет компьютерных наук
Образовательная программа «Анализ больших данных»

МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ

**Прогнозирование валового регионального продукта
(ВРП)
субъектов Российской Федерации с помощью
ансамблевых
методов машинного обучения**

Выполнил:

Семенюченко Артём Геннадьевич
студент ФКН НИУ ВШЭ,
ОП «Анализ больших данных»

Научный руководитель:

Паточенко Евгений Анатольевич
старший преподаватель ФКН НИУ ВШЭ,
академический руководитель
ОП «Анализ больших данных»

Москва 2026

Аннотация

Настоящая работа посвящена разработке воспроизводимого подхода к прогнозированию валового регионального продукта субъектов Российской Федерации на основе панельных временных данных и ансамблевых методов машинного обучения. Эмпирическая база — региональная панель за 2005–2024 годы; горизонт прогнозирования — один год вперёд ($h = 1$). В роли целевой переменной рассматривается логарифм реального ВРП. Признаковое пространство объединяет лаги отклика, производственные и инвестиционные показатели, индикаторы рынка труда, бюджетные параметры, признаки кризисных периодов и характеристики региональной специализации.

Сопоставляются три базовые модели — наивный прогноз, AR(1) и Ridge регрессия с фиксированными эффектами — и три ансамблевых алгоритма: LightGBM, CatBoost и GPBoost. Последний выбран как метод, совмещающий градиентный бустинг со случайными эффектами и позволяющий явно учитывать панельную структуру данных. Качество оценивается на временной валидации по схеме expanding window по метрикам RMSE, MAE и out-of-sample R^2 . Дополнительно проводятся ablation study по блокам признаков и два robustness checks. Особое внимание уделено предотвращению leakage: все preprocessing-операции обучаются исключительно на train-части каждого fold.

Ключевые слова: валовой региональный продукт, машинное обучение, панельные временные ряды, ансамблевые модели, градиентный бустинг, GPBoost, временная валидация, SHAP.

Abstract

This thesis develops a reproducible pipeline for forecasting the Gross Regional Product (GRP) of Russian Federation subjects using panel time-series data and ensemble machine learning methods. The empirical base is a regional panel covering 2005–2024; the forecast horizon is one year ahead ($h = 1$). The target variable is defined as the logarithm of real GRP. The feature space combines lagged values of the target, industrial and investment indicators, labour market statistics, fiscal variables, crisis dummies, and regional specialisation characteristics.

The study compares three baseline models — naive forecast, AR(1), and Ridge regression with fixed effects — and three ensemble algorithms: LightGBM, CatBoost, and GPBoost. GPBoost is selected as a method that combines gradient boosting with Gaussian random effects, explicitly addressing panel heterogeneity without expanding the feature space. Model quality is assessed via expanding-window time-series cross-validation using RMSE, MAE, and out-of-sample R^2 . The experimental design additionally includes an ablation study across feature groups and two robustness checks. Particular attention is paid to leakage prevention: all preprocessing operations are fitted exclusively on the training portion of each fold.

Keywords: gross regional product, machine learning, panel time series, ensemble methods, gradient boosting, GPBoost, time-series validation, SHAP.

Содержание

1 Введение	5
1.1 Актуальность исследования	5
1.2 Объект и предмет исследования	6
1.3 Цель и задачи исследования	6
1.4 Данные и инструментарий	7
1.5 Практическая значимость	7
1.6 Научная новизна	7
2 Обзор литературы	8
2.1 Chi et al. (2025). Macroeconomic Forecasting and Machine Learning [2]	8
2.2 Badykova (2026). Детерминанты ВРП в России: подход машинного обучения [4]	9
2.3 Lashina & Grishunin (2023). Сравнение моделей прогнозирования ВВП России [5]	9
2.4 Sigrist (2022). Gaussian Process Boosting [6]	10
2.5 Сопутствующая литература	10
3 Методология исследования	11
3.1 Формальная постановка задачи	11
3.2 Проверка стационарности	11
3.3 Признаковое пространство	11
3.4 Предотвращение leakage и предобработка	12
3.5 Базовые модели	12
3.6 Ансамблевые модели	12
3.7 Временная валидация и подбор гиперпараметров	13
3.8 Метрики качества	13
4 Результаты экспериментов	14
4.1 Сравнение моделей на скользящей кросс-валидации	14
4.2 Ablation study	15
4.3 Анализ устойчивости	16
4.4 SHAP-интерпретация	16
4.5 Анализ ошибок	18
5 Обсуждение результатов	18
5.1 Сравнительный анализ моделей	18
5.2 Доминирование макропеременных	21
5.3 Ограничения исследования	21

1. Введение

1.1. Актуальность исследования

Валовой региональный продукт занимает центральное место среди показателей экономического развития субъектов Российской Федерации. По экономическому содержанию ВРП близок к ВВП, но рассчитывается для отдельной территории, что позволяет перейти от агрегированного описания к анализу пространственного распределения выпуска и неоднородной реакции регионов на экономические шоки.

Российская экономика характеризуется выраженной территориальной неоднородностью, обусловленной историей экономического становления страны — централизованностью вокруг крупных городов и большим количеством моногородов — а также особенностями ландшафта и климата (регионы-курорты, добывающие регионы). В результате в одной стране сосуществуют сырьевые, индустриальные, аграрные и бюджетно-зависимые регионы, каждый из которых обладает собственным механизмом формирования валового продукта. Прикладную значимость исследования усиливает лаг публикации официальной статистики: по данным Росстата, объём ВРП по сумме субъектов за 2024 год в текущих ценах составил 186 545,1 млрд руб., индекс физического объёма — 104,4% [1]. Эти оценки появляются после завершения отчётного периода, тогда как региональный мониторинг и бюджетное планирование требуют более оперативной картины динамики выпуска.

Сама задача относится к классу регрессии на панельных временных данных. Наблюдением выступает пара «регион — год», целевой переменной — будущее значение ВРП, признаками — лаговая информация и социально-экономические показатели региона. Такая структура отличается от классического одномерного временного ряда: модель должна одновременно учитывать временную зависимость, межрегиональную неоднородность, различие масштабов субъектов и возможные структурные разрывы. Дополнительная сложность состоит в риске утечки информации из будущего: применение стандартных процедур кросс-валидации без учёта временного порядка систематически завышает оценки качества. Cerqua, Letta и Pinto [3] показывают, что leakage в панельных данных имеет несколько источников, не сводимых к простому «подглядыванию» в тестовую выборку.

Современная литература по macro-ML подчёркивает, что применение машинного обучения оправдано лишь при строгой

экспериментальной процедуре [2]. Соответственно, ансамблевые методы рассматриваются в данной работе не как заведомо более точные, а как гипотеза, подлежащая проверке относительно сильных базовых моделей.

1.2. Объект и предмет исследования

Объектом исследования выступают панельные временные ряды социально-экономических показателей субъектов Российской Федерации. *Предметом* — методы прогнозирования ВРП на этих данных, охватывающие как эконометрические базовые модели, так и ансамблевые алгоритмы машинного обучения.

1.3. Цель и задачи исследования

Цель работы — разработка и оценка воспроизводимого пайплайна прогнозирования ВРП субъектов Российской Федерации на панельных временных данных с использованием эконометрических базовых моделей и ансамблевых методов машинного обучения.

Для достижения цели решаются следующие задачи:

1. Провести обзор литературы по макроэкономическому и региональному прогнозированию, включая современные ML-подходы.
2. Сформировать панельную базу данных за 2005–2024 годы, проверить стационарность и определить целевую переменную.
3. Реализовать предобработку данных и leakage-free процедуру формирования признаков.
4. Построить базовые модели (наивный прогноз, AR(1), Ridge с FE) и ансамблевые алгоритмы (LightGBM, CatBoost, GPBoost).
5. Реализовать временную валидацию по схеме expanding window и подбор гиперпараметров строго внутри train-части каждого fold.
6. Сравнить модели по RMSE, MAE и out-of-sample R^2 .
7. Провести ablation study по блокам признаков и robustness checks.
8. Построить SHAP-интерпретацию лучшей модели.

1.4. Данные и инструментарий

Информационная база формируется на основе данных Росстата, ЕМИСС, Банка России, Минэкономразвития и Федерального казначейства за 2005–2024 годы. В признаковое пространство включены лаги ВРП, индекс промышленного производства, показатели добычи и обработки, сельское хозяйство, строительство, транспорт, торговля, инвестиции в основной капитал, занятость, безработица, заработная плата, доходы населения, доходы и расходы региональных бюджетов, трансферты, федеральный округ и dummy-переменные кризисных периодов.

Используемые библиотеки: `pandas 2.2`, `numpy 1.26` — работа с данными; `scikit-learn 1.4` — линейные модели, валидация, масштабирование; `lightgbm 4.3`, `catboost 1.2` — бустинговые алгоритмы; `grboost 1.5` — модель со смешанными эффектами; `linearmodels 6.0` — панельные регрессии с фиксированными эффектами; `optuna 3.6` — подбор гиперпараметров; `shap 0.45` — интерпретация; `matplotlib 3.8`, `seaborn 0.13` — визуализация. Реализация выполнена на Python 3.11. Воспроизводимость обеспечивается фиксацией `random_state=42` во всех стохастических процедурах и сохранением конфигураций в YAML-файлах.

1.5. Практическая значимость

Результаты могут использоваться для мониторинга региональной экономической динамики, предварительной оценки ВРП до публикации официальной статистики и построения сценарных прогнозов. SHAP-разложения позволяют сопоставить выявленные факторы с экономической логикой регионов, что делает модель пригодной для содержательного аналитического использования.

1.6. Научная новизна

В существующих российских исследованиях акцент делается либо на детерминантах ВРП [4], либо на сценарном прогнозе для отдельного региона [10]. Новизна настоящей работы — в формировании единого экспериментального фреймворка: прогнозирование ВРП как регрессия на панельных временных данных с временной валидацией, явным контролем `leakage`, `ablation study`, `robustness checks` и SHAP-интерпретацией на единой панели субъектов. Дополнительно в сравнение включён `GPBoost` — алгоритм, совмещающий градиентный бустинг

со случайными эффектами и ранее не применявшийся к задаче прогнозирования ВРП российских регионов.

2. Обзор литературы

Задача прогнозирования ВРП пересекается с несколькими исследовательскими направлениями: макроэкономическое прогнозирование, машинное обучение на панельных данных и интерпретируемые модели. Ниже детально разбираются четыре работы, наиболее значимых для методологии настоящего исследования, а затем кратко резюмируется сопутствующая литература.

2.1. Chi et al. (2025). Macroeconomic Forecasting and Machine Learning [2]

Постановка. В рамках данной работы акцент смещается с точечного прогнозирования среднего на условное распределение макроэкономических результатов с помощью машинного обучения. Рассматривается задача прогнозирования уровня безработицы с длительным горизонтом. Методологически статья объединяет три элемента современной прогнозной практики: работу с высокоразмерными данными, регуляризацию для контроля сложности модели и строгую out-of-sample валидацию.

Метод и ключевые результаты. В статье используются глубокие нейронные сети для прогнозирования квантилей распределения. В качестве функции потерь применяется pinball loss (квантильная регрессия). Авторы применяют expanding-window схему: модель обучается только на прошлых наблюдениях, гиперпараметры подбираются на валидационном периоде, качество проверяется на тестовом периоде. Главный результат: регуляризация играет решающую роль. Без shrinkage высокоразмерная модель извлекает шум, а не устойчивый макроэкономический сигнал. Нелинейные преобразования дают лишь ограниченный прирост точности — основную роль играет дисциплинированная процедура отбора сложности и корректная out-of-sample валидация.

Значимость для настоящей работы. Статья задаёт методологический стандарт для применения ML в макроэкономике: сложные модели сравниваются с базовыми только во вневыборочной процедуре. Вывод об ограниченной роли нелинейности предостерегает

от автоматического ожидания превосходства ансамблевых методов над линейными.

2.2. Badykova (2026). Детерминанты ВРП в России: подход машинного обучения [4]

Постановка. Автор анализирует детерминанты ВРП на душу населения по 85 регионам России за 2013–2023 годы. Задача поставлена как объяснение (feature importance), а не как прогнозирование.

Метод и результаты. Основным алгоритмом выступает LightGBM. Интерпретация построена на SHAP: глобальный анализ показывает важность признаков по всей выборке, локальный — объясняет отклонения конкретных регионов. Наиболее значимыми предикторами оказались инвестиции в основной капитал и занятость в обрабатывающей промышленности.

Отличие от настоящей работы. Badykova решает задачу объяснения, а не прогнозирования. Настоящая работа переориентирована на вневыборочный прогноз с временной валидацией, tuning только внутри train, ablation study и явным контролем leakage. Кроме того, в сравнение добавлен GPBoost.

2.3. Lashina & Grishunin (2023). Сравнение моделей прогнозирования ВВП России [5]

Постановка. Авторы сопоставляют прогностическую точность четырёх классов моделей применительно к ВВП России в условиях кризисных периодов: ARIMA, VAR, SVR и CatBoost. Исследование охватывает кризисы 2014–2015 и 2020 годов.

Ключевые результаты. CatBoost демонстрирует наилучшее качество в кризисные периоды, превосходя ARIMA и VAR по RMSE и MAPE. В стабильные периоды разница сокращается. Работа является единственной в рассмотренной литературе, сравнивающей CatBoost с классическими эконометрическими моделями на данных ВВП России и охватывающей кризисные периоды.

Значимость. Результаты обосновывают включение CatBoost в сравнение и мотивируют отдельный анализ качества моделей в кризисные годы (robustness check).

2.4. Sigrist (2022). Gaussian Process Boosting [6]

Постановка. Работа предлагает алгоритм GPBoost, объединяющий градиентный бустинг с гауссовыми процессами и моделями смешанных эффектов. Мотивация: стандартный бустинг моделирует только условное среднее $\mathbb{E}[y \mid X]$, тогда как в панельных данных остатки систематически коррелированы внутри групп (регионов), что снижает эффективность оценки.

Модель. Совместная спецификация:

$$y_{i,t} = F(X_{i,t}) + b_i + \varepsilon_{i,t}, \quad b_i \sim \mathcal{N}(0, \sigma_b^2), \quad \varepsilon_{i,t} \sim \mathcal{N}(0, \sigma^2), \quad (1)$$

где $F(\cdot) = \sum_m \eta T_m(\cdot)$ — аддитивная функция деревьев, b_i — случайный эффект региона i .

Значимость для настоящей работы. GPBoost включён как алгоритм, специально предназначенный для панельной структуры. Это позволяет проверить, даёт ли явное моделирование региональной гетерогенности прирост качества сверх стандартного бустинга.

2.5. Сопутствующая литература

Наукастинг. Цукарев и соавторы [8] сравнивают методы bridge equations и MIDAS с ML-алгоритмами на данных Армении и Беларуси, показывая преимущество бустинга на агрегированных годовых данных. Макеева и Станкевич [9] применяют MIDAS и MFBVAR для оперативной оценки ВВП России.

Региональные исследования. Малкина, Сочков и Капустина [10] разрабатывают нейросетевые сценарные прогнозы ВРП Нижегородской области. Банк России [11] показывает, что целесообразность ML следует проверять отдельно для каждой группы регионов.

Интерпретируемость и ML-дизайн. Lundberg и Lee [15] разработали SHAP-разложение; в настоящей работе SHAP применяется для проверки экономической согласованности модели, а не как инструмент причинной идентификации. Смирнов [7] предупреждает, что прирост ML относительно классических моделей на традиционных данных нередко умеренный — этот тезис усиливает необходимость строгого сравнения с наивным прогнозом и AR(1).

3. Методология исследования

3.1. Формальная постановка задачи

Пусть $i \in \{1, \dots, N\}$ — субъект Федерации, $t \in \{1, \dots, T\}$ — год, $h = 1$ — горизонт прогноза. Задача состоит в нахождении функции f_θ такой, что

$$\hat{y}_{i,t+1} = f_\theta(X_{i,t}^{\text{available}}), \quad (2)$$

где $y_{i,t} = \log(\text{GRP}_{i,t}^{\text{real}})$ — логарифм реального ВРП, $X_{i,t}^{\text{available}}$ — вектор признаков, содержащий только информацию, доступную к моменту t . Множество данных:

$$\mathcal{D} = \{(X_{i,t}, y_{i,t+1}) : i = 1, \dots, N; t = p, \dots, T-1\}, \quad (3)$$

где p — максимальный лаг признаков.

3.2. Проверка стационарности

Перед построением моделей проводится проверка стационарности. Для каждого региона применяется расширенный тест Дики – Фуллера (ADF) на логарифм ВРП и его первую разность. На уровне панели используется тест Im – Pesaran – Shin (IPS), допускающий неодинаковые авторегрессионные коэффициенты по регионам. Гипотеза о нестационарности уровня ВРП ожидаемо не отвергается; первые разности предположительно стационарны. Эти результаты обосновывают включение лагов ВРП как признаков.

3.3. Признаковое пространство

Признаковая система строится как экономически мотивированная структура:

$$X_{i,t} = [X_{i,t}^{\text{lag}}, X_{i,t}^{\text{prod}}, X_{i,t}^{\text{inv}}, X_{i,t}^{\text{lab}}, X_{i,t}^{\text{bud}}, X_{i,t}^{\text{cat}}, X_t^{\text{shock}}]. \quad (4)$$

Инерционный блок объединяет лаги ВРП $y_{i,t-1}$, $y_{i,t-2}$ и скользящие средние. *Производственный* — показатели добычи, обработки, промышленности, сельского хозяйства, строительства, транспорта и торговли. *Инвестиционный* — инвестиции в основной капитал, инвестиции на душу населения, отношение инвестиций к ВРП. *Социально-трудовой* — занятость, безработица, заработная плата, доходы населения. *Бюджетный* — доходы и расходы бюджета, трансферты, бюджетные инвестиции. *Категориальный блок* — федеральный округ

и индикаторы специализации (сырьевая, индустриальная, аграрная, сервисная, бюджетно-зависимая). Блок шоков — dummy кризисных периодов 2008–2009, 2014–2015, 2020 и 2022–2023 годов.

3.4. Предотвращение leakage и предобработка

Применительно к панельным данным leakage имеет несколько источников [3]. Базовое правило:

$$X_{i,t}^{\text{available}} = \{x_{i,s}^{(j)} : s \leq t - \ell_j, j = 1, \dots, p\}, \quad (5)$$

где $\ell_j \geq 1$ — лаг доступности признака. Все операции нормализации и импутации обучаются исключительно на Train_k и применяются к Test_k . Денежные показатели дефлируются индексами потребительских цен. Для масштабирования применяется RobustScaler:

$$x_{\text{scaled}} = \frac{x - Q_2}{Q_3 - Q_1}, \quad (6)$$

где Q_1, Q_2, Q_3 — квартили обучающей выборки. Выбор RobustScaler перед StandardScaler обусловлен структурными выбросами (ХМАО, ЯНАО, Москва), не являющимися ошибками измерения, но способными смещать оценку дисперсии.

3.5. Базовые модели

В работе используются три базовые модели, представляющие нарастающую сложность спецификаций.

Наивный прогноз воспроизводит последнее известное значение: $\hat{y}_{i,t+1} = y_{i,t}$.

AR(1) по регионам оценивается отдельно для каждого субъекта: $y_{i,t+1} = \alpha_i + \rho_i y_{i,t} + \varepsilon_{i,t+1}$.

Ridge с фиксированными эффектами объединяет индивидуальные константы региона и временных периодов с L2-регуляризацией полного набора признаков:

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \left[\sum_{i,t} (y_{i,t+1} - \alpha_i - \delta_t - X_{i,t}^{\top} \beta)^2 + \lambda \|\beta\|_2^2 \right]. \quad (7)$$

3.6. Ансамблевые модели

В работе сравниваются три ансамблевых алгоритма.

LightGBM [17] реализует градиентный бустинг на деревьях с leaf-wise стратегией роста, эксклюзивным разбиением признаков (EFB) и гистограммным методом. Алгоритм выбран как основной представитель класса gradient boosting ввиду высокой вычислительной эффективности.

CatBoost [18] применяет ordered boosting для устранения target leakage при обработке категориальных признаков и использует симметричные деревья. По результатам Lashina & Grishunin [5] демонстрирует наилучшее качество на российских данных в кризисные периоды.

GPBoost [6] совмещает бустинг со случайными эффектами регионов:

$$y_{i,t} = F(X_{i,t}) + b_i + \varepsilon_{i,t}, \quad b_i \sim \mathcal{N}(0, \sigma_b^2), \quad \varepsilon_{i,t} \sim \mathcal{N}(0, \sigma^2). \quad (8)$$

В отличие от включения dummy-переменных регионов, GPBoost оценивает случайные эффекты ковариационно, не увеличивая размерность признакового пространства и позволяя строить прогнозы для регионов с короткой историей наблюдений.

3.7. Временная валидация и подбор гиперпараметров

Основная схема — expanding window:

$$\text{Train}_k = \{(i, t) : t \leq \tau_k\}, \quad \text{Test}_k = \{(i, t) : t = \tau_k + 1\}. \quad (9)$$

Начальное окно обучения — не менее десяти лет (2005–2014), τ_k последовательно увеличивается. Итоговый размер — восемь-десять fold’ов.

Подбор гиперпараметров выполняется через дополнительное внутреннее разбиение $\text{Train}_k = \text{Train}_k^{\text{inner}} \cup \text{Val}_k^{\text{inner}}$ с условием $\max(\text{Train}_k^{\text{inner}}) < \min(\text{Val}_k^{\text{inner}})$. Параметры выбираются через Optuna (TPE sampler), после чего модель переобучается на полном Train_k .

3.8. Метрики качества

Основные метрики для сравнения моделей:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_j (y_j - \hat{y}_j)^2}, \quad \text{MAE} = \frac{1}{n} \sum_j |y_j - \hat{y}_j|, \quad (10)$$

$$R_{\text{OOS}}^2 = 1 - \frac{\sum_j (y_j - \hat{y}_j)^2}{\sum_j (y_j - \hat{y}_j^{\text{bench}})^2}, \quad (11)$$

где в знаменателе R_{OOS}^2 в качестве benchmark используется наивный прогноз. Положительный R_{OOS}^2 означает, что модель превосходит наивный прогноз за пределами обучающей выборки.

4. Результаты экспериментов

4.1. Сравнение моделей на скользящей кросс-валидации

Кросс-валидация выполнена на расширяющемся окне из девяти fold'ов (тестовые годы 2015–2023) на панели 85 субъектов Российской Федерации за период 2005–2023. Целевая переменная — темп прироста логарифма реального ВВП: $\Delta \log \text{VRP}_{i,t} = \log \text{VRP}_{i,t} - \log \text{VRP}_{i,t-1}$. Бенчмарком служит наивный прогноз (среднее темпа роста по обучающим годам).

Модель	RMSE	MAE	R_{OOS}^2
CatBoost	0.0395±0.015	0.0300±0.013	0.053±0.44
LightGBM	0.0410±0.015	0.0314±0.013	−0.005±0.49
Наивный прогноз	0.0419±0.012	0.0331±0.010	0.000
AR(1)	0.0487±0.022	0.0336±0.012	−0.40±0.89
Ridge с FE	0.0699±0.057	0.0603±0.060	−2.51±5.21
GPBoost	0.1937±0.166	0.1399±0.125	−34.91±55.35

CatBoost занял первое место по всем трём метрикам. RMSE снижен относительно наивного прогноза на 5,8%; $R_{OOS}^2 = 0,053 > 0$ подтверждает, что модель превосходит бенчмарк вне обучающей выборки. Лучший отдельный fold — CatBoost на тестовом 2019 г.: RMSE = 0.0248, MAE = 0.0172, $R_{OOS}^2 = 0,13$.

model	RMSE	MAE	OOS_R2
CatBoostForecaster	0.0395 +/- 0.0147	0.0300 +/- 0.0130	0.0532 +/- 0.4429
LightGBMForecaster	0.0410 +/- 0.0148	0.0314 +/- 0.0127	-0.0052 +/- 0.4873
NaiveForecaster	0.0419 +/- 0.0117	0.0331 +/- 0.0104	0.0000 +/- 0.0000
AR1Forecaster	0.0487 +/- 0.0216	0.0336 +/- 0.0120	-0.4036 +/- 0.8911
RidgeFEForecaster	0.0699 +/- 0.0572	0.0603 +/- 0.0602	-2.5064 +/- 5.2146
GPBoostForecaster	0.1937 +/- 0.1657	0.1399 +/- 0.1248	-34.9102 +/- 55.3486




Рис. 1: Сводная таблица метрик по моделям (слева) и динамика RMSE по тестовым годам 2015–2023 (справа).

4.2. Ablation study

Ablation study последовательно добавляет блоки признаков к лучшей ансамблевой модели (CatBoost):

- **A0** — только лаги ВРП (LAG_BLOCK);
- **A1** — A0 + производственный и инвестиционный блоки;
- **A2** — A1 + социально-трудовой и бюджетный блоки;
- **A3** — полный набор (A2 + макро, цены, категориальные признаки, кризисные dummy).

Сценарий	RMSE	MAE	R^2_{OOS}
A0	0.0454	0.0362	-0.268
A1	0.0424	0.0337	-0.108
A2	0.0442	0.0350	-0.203
A3	0.0406	0.0310	0.017

Положительный R^2_{OOS} достигается только в полной спецификации A3. Наибольший прирост точности даёт добавление производственного и инвестиционного блоков (переход A0 → A1). Трудовой и бюджетный блоки в изоляции незначительно ухудшают RMSE (A2 хуже A1), что объясняется высокой долей пропусков в ряде бюджетных показателей и вносимым ими шумом на коротком временном ряду.




Рис. 2: Ablation study: прирост точности прогноза при последовательном добавлении блоков признаков к CatBoost.

4.3. Анализ устойчивости

Проведены два robustness check.

RC1 — исключение регионов-выбросов. Из обучающей и тестовой выборок удалены четыре региона, доминирующих по масштабу ВРП: Москва, Ханты-Мансийский АО, Ямало-Ненецкий АО и Сахалинская область. CatBoost сохранил лидерство, что подтверждает: результаты не обусловлены несколькими структурными выбросами.

RC2 — кризисные против нормальных периодов. Fold'ы разделены на кризисные (2008–2009, 2014–2015, 2020, 2022–2023) и некризисные годы. CatBoost остаётся лучшей моделью в обеих подгруппах, подтверждая тезис Lashina & Grishunin [5] о преимуществе бустинга в условиях структурных разрывов.




Рис. 3: RC1: сравнение метрик с выбросами и без них (слева). RC2: RMSE в кризисные и некризисные периоды (справа).

4.4. SHAP-интерпретация

Для CatBoost построено SHAP-разложение:

$$\hat{y}_{i,t} = \phi_0 + \sum_{j=1}^p \phi_{j,i,t}, \quad (12)$$

где $\phi_{j,i,t}$ — вклад признака j в прогноз для региона i в году t . Глобальная значимость: $I_j = \frac{1}{n} \sum_{i,t} |\phi_{j,i,t}|$.

Пять признаков с наибольшим средним $|\phi_j|$:

1. `policy_rate_real_lag1` — реальная ключевая ставка ЦБ РФ;
2. `usd_rub_range_lag1` — диапазон курса доллара за год;
3. `usd_rub_volatility_lag1` — волатильность курса доллара;
4. `crisis_2020` — индикатор пандемийного года;
5. `policy_rate_change_lag1` — изменение ключевой ставки.

Макро-монетарные переменные доминируют над отраслевыми показателями, что согласуется с централизованной монетарной архитектурой России: региональные экономики в значительной мере однородно реагируют на федеральные монетарные шоки.




Рис. 4: Глобальный SHAP-анализ CatBoost: среднее $|\phi_j|$ по признакам (слева) и распределение SHAP-значений по наблюдениям (справа).




Рис. 5: Групповой SHAP: вклад блоков признаков в разрезе типов регионов.

Локальный анализ выполнен для пяти репрезентативных субъектов: Санкт-Петербург, ЯНАО, Тамбовская область, Чувашия и Ярославская область. Они представляют различные экономические профили — от ресурсных до бюджетно-зависимых — и позволяют верифицировать направление SHAP-эффектов.




Рис. 6: Локальные SHAP-waterfall: Санкт-Петербург (слева) и ЯНАО (справа).

4.5. Анализ ошибок

Ошибки CatBoost проанализированы в двух разрезах.

По регионам ($MAE_i = \frac{1}{T} \sum_t |y_{i,t} - \hat{y}_{i,t}|$): наибольшие ошибки характерны для регионов с нестационарной структурой экономики и высокой волатильностью ВРП. Детальный рейтинг приведён на рисунке 8.

По годам ($MAE_t = \frac{1}{N} \sum_i |y_{i,t} - \hat{y}_{i,t}|$): кризисные годы дают отчётливые выбросы ошибки у всех моделей; CatBoost сохраняет наименьший MAE даже в кризисные периоды.

5. Обсуждение результатов

5.1. Сравнительный анализ моделей

Победа CatBoost. Ансамблевые методы превзошли все линейные базовые модели. Среди бустинговых алгоритмов лидирует CatBoost, что объясняется несколькими факторами: нативная обработка категориальных признаков (типы регионов, федеральные округа) через ordered boosting снижает риск target leakage; симметричные деревья обеспечивают эффективную регуляризацию на коротком временном ряду; подбор гиперпараметров через Optuna (50 trials на fold, inner expanding-window) позволяет адаптироваться к каждому обучающему окну.




Рис. 7: Локальные SHAP-waterfall: Тамбовская обл. (слева), Чувашия (справа), Ярославская обл. (снизу).




Рис. 8: Топ-20 регионов по MAE прогноза CatBoost (слева) и динамика MAE всех моделей по годам (справа).




Рис. 9: Тепловая карта ошибок прогноза (регион $\times$ год) для 30 субъектов с наибольшим средним MAE.

Провал GPBoost. GPBoost показал наихудшие результаты ($RMSE = 0,194$, $R^2_{OOS} = -34,9$) с экстремально высокой дисперсией между fold'ами. Причина технического характера: при генерации прогнозов на тестовой выборке гауссовская процессная компонента модели отключается (`ignore_gp_model=True`), поскольку условные предсказания случайных эффектов для новых временных периодов технически неустойчивы. Фактически GPBoost деградирует до обычного градиентного бустинга без случайных эффектов — при этом проигрывает CatBoost и LightGBM, использующим ту же парадигму, но с более подходящими пространствами гиперпараметров.

Линейные модели. Ridge с FE демонстрирует отрицательный R^2_{OOS} и высокую дисперсию RMSE. Это нетипично для линейных методов и, вероятно, объясняется неустойчивостью оценки λ во внутренней валидации при малом числе наблюдений в последних двух годах обучающего окна.

5.2. Доминирование макропеременных

SHAP-анализ обнаруживает, что наиболее значимыми предикторами темпа роста ВРП являются монетарные и валютные индикаторы, а не отраслевые показатели производства. Это экономически интерпретируемо: в условиях централизованной денежно-кредитной политики России все регионы реагируют на федеральные монетарные шоки практически однородно, тогда как отраслевая диверсификация проявляется на более коротких временных горизонтах, слабее заметных на годовых данных. Кризисный индикатор 2020 г. в тройке лидеров — свидетельство того, что модель «научилась» значительному снижению темпа роста в пандемийный год и корректно применяет этот эффект при наличии dummy-признака.

Групповой SHAP показывает, что макро-монетарный блок равномерно значим во всех типах регионов, тогда как производственный блок сильнее влияет на прогнозы для сырьевых и индустриальных субъектов, а кризисные dummy — для бюджетно-зависимых.

5.3. Ограничения исследования

1. Около двадцати годовых наблюдений на регион — малая панель ограничивает применение более сложных архитектур.
2. Ретроспективная база не воспроизводит real-time environment: некоторые показатели доступны с лагом публикации, что завышает

оценку практической применимости.

3. Структурные разрывы (2008, 2014, 2020, 2022) затрудняют перенос модели между экономическими режимами.
4. Типология регионов задана статически и не отражает эволюции их экономической структуры.
5. SHAP-значения объясняют прогноз модели, но не доказывают причинности.
6. GP-компонента GPBoost не используется при OOS-прогнозировании, что фактически исключает ключевое методологическое преимущество данного алгоритма.

6. Заключение

В работе задача прогнозирования ВРП субъектов Российской Федерации сформулирована как регрессия на панельных временных данных с горизонтом $h = 1$. Реализован воспроизводимый pipeline: предобработка без утечки данных, скользящая кросс-валидация с расширяющимся окном (9 fold'ов, тестовые годы 2015–2023) и сопоставление шести моделей — наивного прогноза, AR(1), Ridge с FE, LightGBM, CatBoost и GPBoost.

Главный результат: **CatBoost превзошёл все модели** по RMSE, MAE и R^2_{OOS} . RMSE снижен относительно наивного прогноза на 5,8% (0,0395 против 0,0419), $R^2_{OOS} = 0,053$ подтверждает устойчивое превосходство над бенчмарком вне обучающей выборки. Ablation study показал, что только полная спецификация АЗ (все блоки признаков) достигает положительного R^2_{OOS} ; производственный и инвестиционный блоки вносят наибольший прирост точности. Два robustness check — без структурных выбросов и в разрезе кризисных периодов — подтвердили устойчивость ранжирования моделей.

SHAP-интерпретация обнаружила доминирование макро-монетарных признаков (реальная ключевая ставка, волатильность курса доллара) над отраслевыми показателями, что согласуется с централизованным характером монетарной политики в России.

GPBoost неожиданно показал наихудшие результаты: техническое ограничение — отключение GP-компоненты при OOS-прогнозировании — де-факто лишает модель её методологического преимущества и порождает нестабильные прогнозы.

Практическая значимость: прогностические системы для региональных финансовых органов следует строить на основе CatBoost с полным набором признаков; ключевыми опережающими индикаторами являются параметры денежно-кредитной политики, а не отраслевые производственные индексы.

Перспективные направления развития: запуск нейросетевой модели с эмбедингами регионов, добавление метода Диболда-Мариано для статистического подтверждения превосходства CatBoost, исследование устойчивости при увеличении горизонта прогноза ($h = 2, 3$).

Список литературы

- [1] Федеральная служба государственной статистики. Валовой региональный продукт за 2024 год. URL: <https://rosstat.gov.ru/folder/313/document/279001>.
- [2] Chi T.C., Fan T.-H., Ghigliazza R.M., Giannone D., Wang Z. Macroeconomic Forecasting and Machine Learning. *arXiv:2510.11008*, 2025.
- [3] Cerqua A., Letta M., Pinto G. On the (Mis)Use of Machine Learning With Panel Data. *Oxford Bulletin of Economics and Statistics*, 2025.
- [4] Бадыкова И.Р. Валовой региональный продукт: анализ детерминант для России с использованием моделей машинного обучения. *Экономика региона*, 2026. Т. 22. № 1. С. 97–108. DOI: 10.17059/ekon.reg.2026-1-8.
- [5] Lashina M., Grishunin S. Comparison of Forecasting Power of Statistical Models for GDP Growth Under Conditions of Permanent Crises. *Procedia Computer Science*, 2023. Vol. 221. P. 442–449. DOI: 10.1016/j.procs.2023.07.059.
- [6] Sigrist F. Gaussian Process Boosting. *Journal of Machine Learning Research*, 2022. Vol. 23. No. 232. P. 1–46.
- [7] Смирнов С.В. Методы машинного обучения в макроэкономическом прогнозировании: предварительные итоги. *Вопросы экономики*, 2025. № 10. С. 131–154. DOI: 10.32609/0042-8736-2025-10-131-154.
- [8] Цукарев Т., Погосян К., Лемба К., Гришин Д. Наукастинг ВВП: от традиционных эконометрических моделей к машинному обучению. *Рабочий документ ЕФСР*, РД/25/1, 2025. URL: <https://efsd.org/research/working-papers/>.
- [9] Макеева Н.М., Станкевич И.П. Наукастинг элементов использования ВВП России. *Экономический журнал ВШЭ*, 2022. Т. 26. № 4. С. 598–622. DOI: 10.17323/1813-8691-2022-26-4-598-622.
- [10] Малкина М. Ю., Сочков А. Л., Капустина Ю. И. Прогнозирование ВРП региона с применением методов искусственного интеллекта. *Journal of New Economy*, 2025. Т. 26. № 3. С. 67–85. DOI: 10.29141/2658-5081-2025-26-3-4.

- [11] Semiturkin O., Shevelev A. Forecasting Regional Inflation Rates Using Machine Learning Methods: The Case of Siberia Macroregion. *Bank of Russia Working Paper Series*, No. 91, 2022.
- [12] Chernyshova G.Yu., Rasskazkin N.D. Software Implementation of Ensemble Models for the Analysis of Regional Socio-Economic Development Indicators. *Izvestiya of Saratov University. Mathematics. Mechanics. Informatics*, 2022. Vol. 22. Iss. 1. P. 130–137. DOI: 10.18500/1816-9791-2022-22-1-130-137.
- [13] Buckmann M., Potjagailo G. Infusing Economically Motivated Structure into Machine Learning Methods. *Bank of England Staff Working Paper*, 2025.
- [14] Attolico L. Explainable Machine Learning for Macroeconomic and Financial Nowcasting. *arXiv:2512.00399*, 2025.
- [15] Lundberg S.M., Lee S.-I. A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems*, 2017.
- [16] Breiman L. Random Forests. *Machine Learning*, 2001. Vol. 45. P. 5–32.
- [17] Ke G., Meng Q., Finley T., et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems*, 2017.
- [18] Dorogush A.V., Ershov V., Gulin A. CatBoost: Gradient Boosting with Categorical Features Support. *arXiv:1810.11363*, 2018.