

Машинное обучение в прогнозировании валового регионального продукта субъектов Российской Федерации

Предзащита выпускной квалификационной работы

Семенюченко Артём Геннадьевич

Научный руководитель: Паточенко Евгений Анатольевич
Программа «Анализ больших данных», ФКН НИУ ВШЭ

2026

Почему это важно?

- ▶ ВРП — ключевой показатель социально-экономического развития регионов
- ▶ Используется для межбюджетных трансфертов и регионального планирования
- ▶ Официальные данные Росстат публикуются с лагом 1–2 года
- ▶ Традиционные методы (ARIMA, VAR) не учитывают нелинейности и пространственную гетерогенность

Исследовательский вопрос

Могут ли методы ML обеспечить точный прогноз ВРП для 85 регионов РФ на горизонте 1 год, превосходя наивные бенчмарки?

Практическая ценность

Ранняя оценка ВРП позволяет оперативно корректировать политику регионального развития

Цель и задачи исследования

Цель

Разработать ML-пайплайн прогнозирования ВРП регионов РФ с интерпретируемостью через SHAP

Задачи:

1. Панельный датасет 2005–2023, 85 регионов
2. Расширяющееся окно без утечки данных
3. Сравнение бустинга (LGBM, CatBoost, GPBoost) с бенчмарками
4. Аблационный анализ блоков признаков
5. Устойчивость к выбросам и кризисам
6. Глобальный и локальный SHAP-анализ

Новизна работы

- ▶ Первое систематическое сравнение ML-моделей на панельных данных ВРП всех регионов РФ
- ▶ Интеграция GPBoost (гауссовы процессы + бустинг) для учёта пространственной корреляции
- ▶ Блочный SHAP-анализ по типам регионов

Источник: Росстат, база данных показателей субъектов РФ

- ▶ **Период:** 2005–2023 гг.
- ▶ **Объектов:** 85 регионов (отфильтровано ≥ 80 по покрытию)
- ▶ **Целевая переменная:** $\Delta \log(\text{ВРП}_{\text{реал}})$ — темп прироста реального ВРП
- ▶ **Блоки признаков:**
 - Лаги ВРП и темпов роста (AR-компонента)
 - Инвестиции, доходы, промышленность
 - Занятость, демография
 - Бюджетные показатели
 - Временные и региональные эффекты

Предобработка

- ▶ Логарифмирование стоимостных показателей
- ▶ RobustScaler по train-выборке каждого фолда
- ▶ Медианная импутация пропусков
- ▶ Порог пропусков: 40%
- ▶ Исключение признаков с будущей информацией

Кризисные периоды

2008–09, 2014–15, 2020, 2022–23

Методология: расширяющееся скользящее окно

Схема валидации (9 фолдов):

Фолд	Train	Test
1	2005-2014	2015
2	2005-2015	2016
⋮	⋮	⋮
9	2005-2022	2023

- ▶ Минимум 10 лет на обучение
- ▶ **FeatureBuilder** обучается только на train
- ▶ Нет утечки через масштабирование и импутацию

Метрики

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_i (y_i - \hat{y}_i)^2}$$

$$\text{MAE} = \frac{1}{N} \sum_i |y_i - \hat{y}_i|$$

$$\text{OOS-}R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y}_{\text{train}})^2}$$

Бенчмарк

Наивная модель: $\hat{y}_i = \bar{y}_{\text{train}}$
(среднее темпа роста)

Архитектура признаков

Блоки признаков (аблационный анализ):

- ▶ **A0 — Полный набор** (baseline)
- ▶ **A1 — без AR-лагов**: влияние автокорреляции ВРП
- ▶ **A2 — без инвестиций**: роль капитальных вложений
- ▶ **A3 — без доходов**: эффект доходов населения
- ▶ **A4 — без бюджета**: бюджетный канал
- ▶ **A5 — без временных эффектов**: макросинхронизация

Принцип «no leakage»

Все преобразования признаков (скейлинг, импутация, кодирование) применяются строго на train-части каждого фолда. Test-данные преобразуются параметрами, оцененными только на train.

Лаговая структура

Для цели $\Delta \log(\text{ВРП}_t)$ используются значения признаков $t - 1$, что исключает информацию о тестовом периоде.

Модели прогнозирования

ML-модели:

- ▶ **LGBM** — LightGBM, gradient boosting на деревьях
- ▶ **CatBoost** — Yandex, нативная обработка категориальных признаков
- ▶ **Ensemble** — взвешенный ансамбль $CB \times 0.6 + LGB \times 0.4$
- ▶ **GPBoost** — комбинация GB + гауссовы процессы, учёт случайных эффектов регионов

Бенчмарки:

- ▶ **Ridge** — L2-регрессия, перекрёстная валидация λ
- ▶ **AR(1)** — авторегрессия в пространстве темпов роста

Подбор гиперпараметров

- ▶ Optuna TPE, 20 итераций
- ▶ Быстрые trial: `n_estimators` снижен
- ▶ Финальный fit: полные 300/500/300
- ▶ Inner-val: последние 2 года train

Интерпретируемость


`shap.TreeExplainer`: глобальный, групповой и локальный SHAP

Основные результаты: сводная таблица метрик

model	RMSE	MAE	OOS_R2
Ensemble(CB×0.25+LGB×0.75)	0.0382 +/- 0.0129	0.0288 +/- 0.0113	0.1440 +/- 0.3071
LGBMForecaster	0.0388 +/- 0.0121	0.0295 +/- 0.0105	0.1219 +/- 0.2629
CatBoostForecaster	0.0408 +/- 0.0153	0.0311 +/- 0.0135	0.0356 +/- 0.3884
NaiveForecaster	0.0419 +/- 0.0117	0.0331 +/- 0.0104	0.0000 +/- 0.0000
AR1Forecaster	0.0487 +/- 0.0216	0.0336 +/- 0.0120	-0.4036 +/- 0.8911
EmbMLPForecaster	0.0491 +/- 0.0199	0.0378 +/- 0.0166	-0.4386 +/- 0.9218
RidgeFEForecaster	0.0517 +/- 0.0261	0.0419 +/- 0.0273	-0.6176 +/- 1.0868
GPBoostForecaster	0.4882 +/- 0.5955	0.4285 +/- 0.5568	-280.9273 +/- 515.5155

Зелёным — лучшее значение. $OOS-R^2 > 0$: модель превосходит наивный бенчмарк.


Динамика RMSE по годам прогноза




Серые полосы — кризисные периоды (2008-09, 2014-15, 2020, 2022-23). Все модели показывают всплески ошибок в кризисные годы, что ожидаемо.

Ошибки прогноза: региональная структура

Топ-20 регионов по MAE




Тепловая карта ошибок (регион × год)




Наибольшие ошибки — в ресурсодобывающих регионах (ЯНАО, Сахалин) и в периоды структурных шоков.

SHAP: глобальная важность признаков

Средний |SHAP|




Beeswarm (направление эффекта)



#1: волатильность USD/RUB (`usd_rub_volatility_lag1`), отрыв вдвое от следующего. Далее: стоимость прод. корзины, ключевая ставка (ном. и реал.), доля платных услуг. MACRO_BLOCK и PRICE_BLOCK доминируют над отраслевыми показателями.


SHAP: блоки признаков по типам регионов



MACRO_BLOCK (0.21-0.27) и PRICE_BLOCK (0.16-0.21) доминируют во всех типах регионов. PRODUCTION_BLOCK сильнее для сырьевых (0.17 vs 0.08-0.11).


CATEGORICAL_BLOCK = 0 везде — тип региона не добавляет предсказательной

Аблационный анализ блоков признаков



A0 — только лаги ВРП; A3 — полный набор признаков. Добавление производственного блока (A0→A1) даёт заметное улучшение. Остальные блоки (A1→A3) вносят меньший вклад для LightGBM. Пунктир — наивный прогноз.


Исключение структурных выбросов



Полная выборка vs. без Москвы, ХМАО, ЯНАО, Сахалина

ML-модели устойчивы к исключению структурных выбросов: RMSE меняется незначительно. На кризисных фолдах точность падает, однако ML превосходит бенчмарки и в этом режиме.

Кризисные vs. обычные периоды



RMSE на фолдах кризисных лет существенно выше

Заключение и вклад

Основные результаты:

- ▶ Лучшая модель:
Ensemble(CB×0.6+LGB×0.4),
RMSE = 0.0387 (-7.6% от наивного),
OOS- R^2 = 0.126
- ▶ Одиночные: LGBM $\approx$ Ensemble;
CatBoost — 3-й
- ▶ Волатильность USD/RUB и ключевая ставка — топ предикторы (SHAP)
- ▶ Устойчивость к выбросам; ошибки выше в кризисные периоды

Научный вклад

- ▶ Воспроизводимый пайплайн для панельного прогнозирования ВРП
- ▶ Строгая OOS-методология для региональной экономики
- ▶ Блочный SHAP — экономическая интерпретация ML

Практика

Оперативная оценка ВРП для регионального планирования и МБТ

Спасибо за внимание!