

Федеральное государственное автономное образовательное учреждение
высшего образования
**НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»**

Факультет компьютерных наук
Образовательная программа «Анализ больших данных»

МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ

**Прогнозирование валового регионального продукта (ВРП)
субъектов Российской Федерации с помощью ансамблевых
методов машинного обучения**

Выполнил:
Семенюченко Артём Геннадьевич
студент ФКН НИУ ВШЭ,
ОП "Анализ больших данных"

Научный руководитель:
Паточенко Евгений Анатольевич
старший преподаватель ФКН НИУ ВШЭ,
академический руководитель ОП "Анализ больших данных"

Москва 2026

Аннотация

Настоящая работа посвящена разработке воспроизводимого подхода к прогнозированию валового регионального продукта субъектов Российской Федерации на основе панельных временных данных и ансамблевых методов машинного обучения. Эмпирическая база — региональная панель за 2005–2024 годы; горизонт 2025–2026 годов используется для сценарного прогноза. В роли целевой переменной рассматриваются логарифм реального ВРП и темп роста ВРП. Признаковое пространство объединяет лаги отклика, производственные и инвестиционные показатели, индикаторы рынка труда, бюджетные параметры, признаки кризисных периодов и характеристики региональной специализации.

Сопоставляются базовые модели — наивный прогноз, AR(1), регуляризованные линейные регрессии (Ridge, Lasso, ElasticNet) и панельная модель с фиксированными эффектами — и ансамблевые алгоритмы: Random Forest, XGBoost, LightGBM, CatBoost, GPBoost и стэкинг. GPBoost выбран как метод, совмещающий градиентный бустинг со случайными эффектами и позволяющий явно учитывать панельную структуру данных. Качество оценивается на временной валидации в схемах expanding window и rolling window по метрикам RMSE, MAE, MAPE, sMAPE, MASE и out-of-sample R^2 . Дополнительно проводятся ablation study, robustness checks и SHAP-разложение. Особое внимание уделено предотвращению leakage: все preprocessing-операции обучаются исключительно на train-части каждого fold.

Ключевые слова: валовой региональный продукт, машинное обучение, панельные временные ряды, ансамблевые модели, градиентный бустинг, GPBoost, временная валидация, SHAP.

Abstract

This thesis develops a reproducible pipeline for forecasting the Gross Regional Product (GRP) of Russian Federation subjects using panel time-series data and ensemble machine learning methods. The empirical base is a regional panel covering 2005–2024; the forecast horizon is 2025–2026. The target variable is defined as the logarithm of real GRP; robustness checks additionally consider nominal GRP, per-capita GRP, and GRP growth rates. The feature space combines lagged values of the target, industrial and investment indicators, labour market statistics, fiscal variables, crisis dummies, and regional specialisation characteristics.

The study compares two groups of models. Baseline models include the naive forecast, AR(1), regularised linear regressions (Ridge, Lasso, ElasticNet), and a panel fixed-effects model. Ensemble algorithms include Random Forest, XGBoost, LightGBM, CatBoost, GPBoost, and stacking. GPBoost is selected as a method that combines gradient boosting with Gaussian random effects, explicitly addressing panel heterogeneity without expanding the feature space. Model quality is assessed via time-series cross-validation (expanding window and rolling window) using RMSE, MAE, MAPE, sMAPE, MASE, and out-of-sample R^2 . Particular attention is paid to leakage prevention: all preprocessing operations are fitted exclusively on the training portion of each fold.

The experimental design additionally includes ablation study across feature groups, robustness checks (exclusion of largest regions, alternative target definitions, crisis vs. non-crisis periods), and SHAP decomposition to verify the economic consistency of the selected model.

Keywords: gross regional product, machine learning, panel time series, ensemble methods, gradient boosting, GPBoost, time-series validation, SHAP.

Содержание

Аннотация	1
Abstract	2
1 Введение	5
1.1 Актуальность исследования	5
1.2 Объект и предмет исследования	6
1.3 Цель и задачи исследования	6
1.4 Данные и инструментарий	7
1.5 Практическая значимость	7
1.6 Научная новизна	8
2 Обзор литературы	8
2.1 Chi et al. (2025). Macroeconomic Forecasting and Machine Learning [2]	8
2.2 Badykova (2026). Детерминанты ВРП в России: подход машинного обучения [4]	11
2.3 Lashina & Grishunin (2023). Сравнение моделей прогнозирования ВВП России [5]	11
2.4 Sigrist (2022). Gaussian Process Boosting [6]	12
2.5 Сопутствующая литература	13
3 Методология исследования	14
3.1 Формальная постановка задачи	14
3.2 Проверка стационарности	14
3.3 Признаковое пространство	15
3.4 Предотвращение leakage и предобработка	15
3.5 Базовые модели	16
3.6 Ансамблевые модели	16
3.7 Временная валидация и подбор гиперпараметров	17
3.8 Метрики качества	17
4 План экспериментов и интерпретации	17

4.1	Ablation study	17
4.2	Robustness checks	18
4.3	SHAP-интерпретация	18
4.4	Анализ ошибок	18
4.5	Сценарный прогноз на 2025–2026 годы	18
4.6	Ожидаемые результаты и ограничения	18
5	Заключение	19

1. Введение

1.1. Актуальность исследования

Валовой региональный продукт занимает центральное место среди показателей экономического развития субъектов Российской Федерации. По экономическому содержанию ВРП близок к ВВП, но рассчитывается для отдельной территории, что позволяет перейти от агрегированного описания к анализу пространственного распределения выпуска и неоднородной реакции регионов на экономические шоки.

Российская экономика характеризуется выраженной территориальной неоднородностью. Все дело в истории экономического становления страны (централизованность вокруг крупных городов, большое количество городов-предприятий) и, конечно же, ее ландшафта и климатических условия (регионы-курорты, добывающие регионы). Оттого в одной стране существуют сырьевые, индустриальные, аграрные и бюджетно-зависимые регионы, каждый из которых по своему уникален и обладает собственным механизмом формирования валового продукта. Прикладную значимость исследования усиливает лаг публикации официальной статистики: по данным Росстата, объём ВРП по сумме субъектов за 2024 год в текущих ценах составил 186 545,1 млрд руб., индекс физического объёма — 104,4 % [1]. Эти оценки появляются после завершения отчётного периода, тогда как региональный мониторинг и бюджетное планирование требуют более оперативной картины динамики выпуска.

Сама задача относится к классу регрессии на панельных временных данных. Наблюдением выступает пара «регион — год», целевой переменной — будущее значение ВРП, признаками — как лаговая информация, так и социально-экономические показатели региона. Такая структура отличается от классического одномерного временного ряда: модель должна одновременно учитывать временную зависимость, межрегиональную неоднородность, различие масштабов субъектов и возможные структурные разрывы. Дополнительная сложность состоит в риске утечки информации из будущего: применение стандартных процедур кросс-валидации без учёта временного порядка систематически завышает оценки качества. Cerqua, Letta

и Pinto [3] показывают, что leakage в панельных данных имеет несколько источников, не сводимых к простому подглядыванию в тестовую выборку.

Современная литература по macro-ML подчёркивает, что применение машинного обучения оправдано лишь при строгой экспериментальной процедуре [2]. Соответственно, ансамблевые методы рассматриваются в данной работе не как заведомо более точные, а как гипотеза, подлежащая проверке относительно сильных базовых моделей.

1.2. Объект и предмет исследования

Объектом исследования выступают панельные временные ряды социально-экономических показателей субъектов Российской Федерации. Предметом — методы прогнозирования ВРП на этих данных, охватывающие как эконометрические базовые модели, так и ансамблевые алгоритмы машинного обучения.

1.3. Цель и задачи исследования

Цель работы — разработка и оценка воспроизводимого пайплайна прогнозирования ВРП субъектов Российской Федерации на панельных временных данных с использованием эконометрических базовых моделей и ансамблевых методов машинного обучения.

1. Провести обзор литературы по макроэкономическому и региональному прогнозированию, включая современные ML-подходы.
2. Сформировать панельную базу данных за 2005–2024 годы, проверить стационарность и определить целевую переменную.
3. Реализовать предобработку данных и leakage-free процедуру формирования признаков.
4. Построить базовые модели (наивный прогноз, AR(1), Ridge, Lasso, ElasticNet, FE) и ансамблевые алгоритмы (Random Forest, XGBoost, LightGBM, CatBoost, GPBoost, стэкинг).
5. Реализовать временную валидацию (expanding window, rolling window) и подбор гиперпараметров строго внутри train-части каждого fold.

6. Сравнить модели по RMSE, MAE, MAPE, sMAPE, MASE и out-of-sample R^2 .
7. Провести ablation study, robustness checks и SHAP-интерпретацию.

1.4. Данные и инструментарий

Информационная база формируется на основе данных Росстата, ЕМИСС, Банка России, Минэкономразвития и Федерального казначейства за 2005–2024 годы. В признаковое пространство включены лаги ВРП, индекс промышленного производства, показатели добычи и обработки, сельское хозяйство, строительство, транспорт, торговля, инвестиции в основной капитал, занятость, безработица, заработная плата, доходы населения, доходы и расходы региональных бюджетов, трансферты, федеральный округ и dummy-переменные кризисных периодов.

Используемые библиотеки:

1. `pandas` 2.2, `numpy` 1.26 — работа с данными
2. `scikit-learn` 1.4 — линейные модели, валидация, масштабирование
3. `xgboost` 2.0, `lightgbm` 4.3, `catboost` 1.2 — бустинговые алгоритмы
4. `gpboost` 1.5 — модель со смешанными эффектами
5. `linearmodels` 6.0 — панельные регрессии с фиксированными эффектами
6. `optuna` 3.6 — подбор гиперпараметров
7. `shap` 0.45 — интерпретация
8. `matplotlib` 3.8, `seaborn` 0.13 — визуализация

Реализация выполнена на Python 3.11. Воспроизводимость обеспечивается фиксацией `random_state=42` во всех стохастических процедурах и сохранением конфигураций в YAML-файлах.

1.5. Практическая значимость

Результаты могут использоваться для мониторинга региональной экономической динамики, предварительной оценки ВРП до публикации официальной статистики и построения сценарных прогнозов. SHAP-разложения позволяют сопоставить выявленные факторы с экономической

логикой регионов, что делает модель пригодной для содержательного аналитического использования.

1.6. Научная новизна

В существующих российских исследованиях акцент делается либо на детерминантах ВРП [4], либо на сценарном прогнозе для отдельного региона [11]. Новизна настоящей работы — в формировании единого экспериментального фреймворка: прогнозирование ВРП как регрессия на панельных временных данных с временной валидацией, явным контролем leakage, ablation study, robustness checks и SHAP-интерпретацией на единой панели субъектов. Дополнительно в сравнение включён GPRBoost — алгоритм, совмещающий градиентный бустинг со случайными эффектами и ранее не применявшийся к задаче прогнозирования ВРП российских регионов.

2. Обзор литературы

Задача прогнозирования ВРП пересекается с несколькими исследовательскими направлениями: макроэкономическое прогнозирование, машинное обучение на панельных данных и интерпретируемые модели. Ниже детально разбираются пять работ, наиболее значимых для методологии настоящего исследования, а затем кратко резюмируется сопутствующая литература.

2.1. Chi et al. (2025). Macroeconomic Forecasting and Machine Learning [2]

Постановка. В рамках данной работы смещается акцент исследования с точечного прогнозирования среднего на условное распределение макроэкономических результатов с помощью машинного обучения. Рассматривается задача прогнозирования уровня безработицы с учетом темпов промышленного производства с длительным горизонтом прогнозирования. Методологически статья объединяет три элемента современной прогнозной практики:

1. работу с высокоразмерными макроэкономическими и финансовыми данными
2. регуляризацию для контроля сложности модели
3. строгую out-of-sample валидацию

В отличие от работ, где машинное обучение используется как набор готовых алгоритмов, Chi et al. строят единый фреймворк, в котором нейронные сети, сила регуляризации, а также функция потерь выбираются на валидационной выборке.

Метод и экспериментальный дизайн. В статье используются глубокие нейронные сети для прогнозирования квантилей распределения макроэкономической переменной, что позволяет проверить не только центральную траекторию, но и хвосты распределения, то есть оценивать вероятность неблагоприятных сценариев. В качестве функции потерь применяется pinball loss, что используется в задаче квантильной регрессии. Для сопоставления также рассматривается среднеквадратичная ошибка, ориентированная на прогноз условного среднего.

Авторы используют L2-ошибку. Такая регуляризация необходима, поскольку в макроэкономических данных число потенциальных предикторов значительно больше длины временного ряда, отчего высок риск переобучения. Для выбора гиперпараметров используется expanding-window схема: модель обучается только на прошлых наблюдениях, затем на отдельном валидационном периоде подбирается сложность, после чего качество проверяется на тестовом периоде, который не использовался ни при обучении, ни при подборе архитектуры.

Ключевые результаты. Главный результат статьи состоит в том, что регуляризация играет решающую роль. Без shrinkage высокоразмерная модель начинает извлекать не устойчивый макроэкономический сигнал, а шум, поэтому качество вне выборки ухудшается. Требуется отобрать умеренную, не слишком сильную регуляризацию, ибо слишком сильное сжатие уничтожает полезную информацию в предикторах, а слишком слабое приводит к переобучению.

Второй важный вывод - нелинейность. Несмотря на использование DNN и гибких функций активации, нелинейные преобразования дают лишь ограниченный прирост точности. Прогнозы, построенные с Leaky ReLU,

оказываются близки к прогнозам с линейной активацией. Это в свою очередь означает, что в рамках рассматриваемой макроэкономической задачи основную роль играет не сама нелинейность, а дисциплинированная процедура отбора сложности, регуляризация и корректная валидация вне выборки.

Третий результат касается распределительного прогноза. Модель позволяет фиксировать изменение макроэкономических рисков во времени. Авторы показывают, что *downside risks* существенно варьируются, тогда как *upside risks* остаются более стабильными. Это особенно важно для макроэкономического мониторинга, где интерес представляет не только ожидаемое значение показателя, но и вероятность ухудшения ситуации.

И наконец, в статье демонстрируется преимущество квантильного подхода в условиях выбросов и кризисных эпизодов. Прогнозы на базе *pinball loss* оказываются более устойчивыми, чем прогнозы, ориентированные на MSE. В период после вспышки COVID-19 квантильные прогнозы сохраняют стабильность и экономическую интерпретируемость, в то время как прогнозы на базе квадратичной ошибки подвергаются излишней волатильности.

Значимость для настоящей работы. Первой причиной является тот факт, что статья задаёт методологический стандарт для применения ML в макроэкономике: сложные модели должны сравниваться с простыми базовыми спецификациями только во вневыборочной процедуре. Второй причиной служит вывод об ограниченной роли нелинейности, что предостерегает от автоматического ожидания превосходства ансамблевых методов над линейными моделями. В-третьих, акцент на регуляризации напрямую связан с задачей прогнозирования ВРП регионов, где число признаков может быть велико относительно числа годовых наблюдений. В-четвёртых, идея распределительного прогноза и анализа *downside risks* полезна для сценарной части настоящей работы: прогноз ВРП может рассматриваться не только как точечная оценка, но и как инструмент выявления регионов с повышенной вероятностью неблагоприятной динамики.

2.2. Badykova (2026). Детерминанты ВРП в России: подход машинного обучения [4]

Постановка. Автор анализирует детерминанты ВРП на душу населения по 85 регионам России за 2013–2023 годы. Задача поставлена как объяснение (feature importance), а не как прогнозирование; тем не менее методология, набор признаков и схема интерпретации представляют прямой интерес для настоящей работы.

Метод и признаки. Основным алгоритмом выступает LightGBM. Признаки сгруппированы в три блока: трудовые ресурсы (занятость, заработная плата, уровень образования), инвестиции (капиталовложения на душу населения, иностранные инвестиции) и производственный потенциал (добыча, промышленность, сельское хозяйство). Интерпретация построена на SHAP: глобальный анализ показывает важность признаков по всей выборке, локальный — объясняет отклонения конкретных регионов.

Ключевые результаты. Наиболее значимыми предикторами оказались инвестиции в основной капитал и занятость в обрабатывающей промышленности. SHAP-анализ выявил существенную дифференциацию по типам регионов: для сырьевых доминируют показатели добычи, для сервисных — доходы населения и торговля.

Отличие от настоящей работы. Бадыкова решает задачу объяснения, а не прогнозирования. Настоящая работа переориентирована на вневыборочный прогноз: временная валидация, tuning только внутри train, ablation study и явный контроль leakage. Кроме того, здесь рассматривается уровень ВРП (а не только ВРП на душу населения), к сравнению добавлены GPMBoost и стэкинг.

2.3. Lashina & Grishunin (2023). Сравнение моделей прогнозирования ВВП России [5]

Постановка. Авторы сопоставляют прогностическую точность четырёх классов моделей применительно к ВВП России в условиях кризисных периодов: ARIMA, VAR, SVR и CatBoost. Исследование охватывает кризисы 2014–2015 и 2020 годов.

Метод. Для ARIMA и VAR используются стандартные процедуры идентификации и оценки. CatBoost настраивается на скользящем окне с перебором гиперпараметров на валидационном периоде. Качество оценивается по RMSE и MAPE на горизонте 1–4 квартала.

Ключевые результаты. CatBoost демонстрирует наилучшее качество в кризисные периоды, превосходя ARIMA и VAR по обоим метрикам. Авторы объясняют это способностью CatBoost воспроизводить нелинейные взаимодействия в моменты структурных разрывов. В стабильные периоды разница сокращается, и ARIMA оказывается сопоставима с CatBoost.

Значимость для настоящей работы. Это единственная работа в рассмотренной литературе, сравнивающая CatBoost с классическими эконометрическими моделями на данных ВВП России и охватывающая кризисные периоды. Результаты обосновывают приоритетное включение CatBoost в сравнение и мотивируют отдельный анализ качества моделей в кризисные годы (robustness check четвёртой группы).

2.4. Sigrist (2022). Gaussian Process Boosting [6]

Постановка. Работа предлагает алгоритм GPBoost, объединяющий градиентный бустинг с гауссовыми процессами и моделями смешанных эффектов. Мотивация: стандартный бустинг моделирует только условное среднее $\mathbb{E}[y \mid X]$, тогда как в панельных данных остатки систематически коррелированы внутри групп (регионов), что снижает эффективность оценки.

Модель. Совместная спецификация:

$$y_{i,t} = F(X_{i,t}) + b_i + \varepsilon_{i,t}, \quad b_i \sim \mathcal{N}(0, \sigma_b^2), \quad \varepsilon_{i,t} \sim \mathcal{N}(0, \sigma^2), \quad (2.1)$$

где $F(\cdot) = \sum_m \eta T_m(\cdot)$ — аддитивная функция деревьев, b_i — случайный эффект региона i , σ_b^2 и σ^2 — дисперсионные параметры.

Алгоритм оценки. Параметры оцениваются итеративно. На каждом шаге: (1) при фиксированных σ_b^2 , σ^2 строится следующее дерево, минимизирующее обобщённые остатки с учётом ковариационной структуры; (2) при фиксированном F параметры ковариации обновляются методом

максимального правдоподобия. Подобным образом мы получаем совместную оценку нелинейной фиксированной части и случайных эффектов.

Преимущества перед альтернативами. При добавлении бинарных переменных регионов в стандартный бустинг увеличивается число признакового пространства на $N - 1$, что не позволяет явно оценить дисперсию случайного эффекта. В рассматриваемой модели данная проблема решается с помощью ковариаций: случайные эффекты оцениваются как латентные переменные, а прогноз для новой группы строится через предсказание случайного эффекта из ковариационной структуры.

Значимость для настоящей работы. GPBoost включён как дополнительный ансамблевый алгоритм, специально предназначенный для панельной структуры. Это позволяет проверить, даёт ли явное моделирование региональной гетерогенности прирост качества сверх стандартного бустинга.

2.5. Сопутствующая литература

Наукастинг. Для справки, наукастинг - предсказания настоящего или максимально приближенных периодов прошлого или будущего. В своей совместной работе Foroni и Marcellino [10] систематизируют методы bridge equations, MIDAS и mixed-frequency VAR. Цукарев и соавторы [8] сравнивают эти методы с ML-алгоритмами на данных Армении и Беларуси, показывая тем самым преимущество бустинга над Bridge/MIDAS на агрегированных годовых данных. Макеева и Станкевич [9] применяют MIDAS и MFBVAR для оперативной оценки ВВП России.

Региональные исследования. Малкина, Сочков и Капустина [11] разрабатывают нейросетевые сценарные прогнозы ВРП Нижегородской области. Банк России [12] показывает, что целесообразность ML следует проверять отдельно для каждой группы регионов. Чернышова и Раскажкин [13] применяют GPBoost к анализу регионального социально-экономического развития.

Интерпретируемость и ML-дизайн. Lundberg и Lee [16] разработали SHAP-разложение; в настоящей работе SHAP применяется для проверки экономической согласованности модели, а не как инструмент причинной идентификации. Buckmann и Potjagailo [14] и Attolico [15] подчёрки-

вают, что интерпретируемость должна быть структурным элементом прогнозного pipeline. Смирнов [7] предупреждает, что прирост ML относительно классических моделей на традиционных данных нередко умеренный — этот тезис усиливает необходимость строгого сравнения с наивным прогнозом и AR(1).

3. Методология исследования

3.1. Формальная постановка задачи

Пусть $i \in \{1, \dots, N\}$ — субъект Федерации, $t \in \{1, \dots, T\}$ — год, h — горизонт прогноза. Задача состоит в нахождении функции f_θ такой, что

$$\hat{y}_{i,t+h} = f_\theta(X_{i,t}^{available}), \quad (3.1)$$

где $y_{i,t} = \log(GRP_{i,t}^{real})$ — логарифм реального ВРП, $X_{i,t}^{available}$ — вектор признаков, содержащий только информацию, доступную к моменту t . Основным горизонтом является $h = 1$; $h = 2$ рассматривается как дополнительный. Множество данных:

$$\mathcal{D} = \{(X_{i,t}, y_{i,t+h}) : i = 1, \dots, N; t = p, \dots, T - h\}, \quad (3.2)$$

где p — максимальный лаг признаков. В robustness checks рассматриваются: $y_{i,t}^{nom} = \log(GRP_{i,t}^{nom})$, $y_{i,t}^{pc} = \log(GRP_{i,t}^{real} / Pop_{i,t})$, $y_{i,t}^{gr} = \Delta \log(GRP_{i,t}^{real})$.

3.2. Проверка стационарности

Перед построением моделей проводится проверка стационарности. Для каждого региона применяется расширенный тест Дики–Фуллера (ADF) на логарифм ВРП и его первую разность. На уровне панели используется тест Im–Pesaran–Shin (IPS), допускающий неодинаковые авторегрессионные коэффициенты по регионам. Гипотеза о нестационарности уровня ВРП ожидаемо не отвергается; первые разности предположительно стационарны. Эти результаты обосновывают включение лагов ВРП как признаков и рассмотрение темпов роста как альтернативного отклика.

3.3. Признаковое пространство

Признаковая система строится как экономически мотивированная структура:

$$X_{i,t} = \left[X_{i,t}^{lag}, X_{i,t}^{prod}, X_{i,t}^{inv}, X_{i,t}^{lab}, X_{i,t}^{bud}, X_i^{cat}, X_t^{shock} \right]. \quad (3.3)$$

Инерционный блок объединяет лаги ВРП $y_{i,t-1}, y_{i,t-2}$, темпы роста и скользящие средние. Производственный — показатели добычи, обработки, промышленности, сельского хозяйства, строительства, транспорта и торговли. Инвестиционный — инвестиции в основной капитал, инвестиции на душу населения, отношение инвестиций к ВРП. Социально-трудовой — занятость, безработица, заработная плата, доходы населения. Бюджетный — доходы и расходы бюджета, трансферты, бюджетные инвестиции. Категориальный блок — федеральный округ и индикаторы специализации (сырьевая, индустриальная, аграрная, сервисная, бюджетно-зависимая). Блок шоков — dummy кризисных периодов 2008–2009, 2014–2015, 2020 и 2022–2023 годов.

3.4. Предотвращение leakage и предобработка

Применительно к панельным данным leakage имеет несколько источников [3]. Базовое правило:

$$X_{i,t}^{available} = \{x_{i,s}^{(j)} : s \leq t - \ell_j, j = 1, \dots, p\}, \quad (3.4)$$

где $\ell_j \geq 1$ — лаг доступности признака. Все операции нормализации и импутации обучаются исключительно на $Train_k$ и применяются к $Test_k$.

Денежные показатели дефлируются. Для масштабирования применяется RobustScaler:

$$x_{scaled} = \frac{x - Q_2}{Q_3 - Q_1}, \quad (3.5)$$

где Q_1, Q_2, Q_3 — квартили обучающей выборки. Выбор RobustScaler перед StandardScaler обусловлен структурными выбросами (ХМАО, ЯНАО, Москва), не являющимися ошибками измерения, но способными смещать оценку дисперсии.

3.5. Базовые модели

- Наивный прогноз: $\hat{y}_{i,t+1} = y_{i,t}$;
- AR(1): $y_{i,t+1} = \alpha_i + \rho y_{i,t} + \varepsilon_{i,t+1}$;
- Ridge: $\hat{\beta}^{ridge} = \arg \min_{\beta} [\sum (y_{i,t+1} - X_{i,t}^{\top} \beta)^2 + \lambda \|\beta\|_2^2]$;
- Lasso: $\hat{\beta}^{lasso} = \arg \min_{\beta} [\sum (y_{i,t+1} - X_{i,t}^{\top} \beta)^2 + \lambda \|\beta\|_1]$;
- ElasticNet: $\hat{\beta}^{EN} = \arg \min_{\beta} [\sum (y_{i,t+1} - X_{i,t}^{\top} \beta)^2 + \lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2]$;
- Панельная модель с FE: $y_{i,t+1} = \alpha_i + \delta_t + X_{i,t}^{\top} \beta + \varepsilon_{i,t+1}$.

3.6. Ансамблевые модели

Random Forest [17]:

$$\hat{f}_{RF}(x) = \frac{1}{M} \sum_{m=1}^M T_m(x). \quad (3.6)$$

Gradient Boosting: $\hat{f}_M(x) = \sum_{m=1}^M \eta T_m(x)$. Реализации XGBoost [18], LightGBM [19] и CatBoost [20] различаются регуляризацией, построением деревьев и обработкой категориальных признаков.

GPBoost [6] совмещает бустинг со случайными эффектами регионов:

$$y_{i,t} = F(X_{i,t}) + b_i + \varepsilon_{i,t}, \quad b_i \sim \mathcal{N}(0, \sigma_b^2), \quad \varepsilon_{i,t} \sim \mathcal{N}(0, \sigma^2). \quad (3.7)$$

В отличие от включения dummy-переменных регионов, GPBoost оценивает случайные эффекты ковариационно, не увеличивая размерность пространства признаков.

Стэкинг. Обучающая выборка $Train_k$ делится на S sub-folds по времени. Базовые модели $f_1, \dots, f_K$ обучаются на sub-folds $1, \dots, s-1$ и генерируют OOF-предсказания на sub-fold s . Собранные OOF-предсказания образуют матрицу признаков для метамодели Ridge. Затем базовые модели дообучаются на полном $Train_k$, их предсказания на $Test_k$ подаются в метамодель:

$$\hat{y}_{i,t+1} = g(\hat{y}_{i,t+1}^{(1)}, \dots, \hat{y}_{i,t+1}^{(K)}). \quad (3.8)$$

3.7. Временная валидация и подбор гиперпараметров

Основная схема — expanding window:

$$Train_k = \{(i, t) : t \leq \tau_k\}, \quad Test_k = \{(i, t) : t = \tau_k + 1\}. \quad (3.9)$$

Дополнительная — rolling window:

$$Train_k = \{(i, t) : \tau_k - w + 1 \leq t \leq \tau_k\}, \quad Test_k = \{(i, t) : t = \tau_k + 1\}. \quad (3.10)$$

Подбор гиперпараметров — через дополнительное внутреннее разбиение $Train_k = Train_k^{inner} \cup Val_k^{inner}$ ($\max(Train_k^{inner}) < \min(Val_k^{inner})$). Параметры выбираются через Optuna (ТРЕ), после чего модель переобучается на полном $Train_k$.

3.8. Метрики качества

$$RMSE = \sqrt{\frac{1}{n} \sum_j (y_j - \hat{y}_j)^2}, \quad MAE = \frac{1}{n} \sum_j |y_j - \hat{y}_j|, \quad (3.11)$$

$$MAPE = \frac{100}{n} \sum_j \left| \frac{y_j - \hat{y}_j}{y_j} \right|, \quad sMAPE = \frac{100}{n} \sum_j \frac{2|y_j - \hat{y}_j|}{|y_j| + |\hat{y}_j|}, \quad (3.12)$$

$$MASE = \frac{\frac{1}{n} \sum_j |y_j - \hat{y}_j|}{\frac{1}{n-1} \sum_{j=2}^n |y_j - y_{j-1}|}, \quad R_{OOS}^2 = 1 - \frac{\sum_j (y_j - \hat{y}_j)^2}{\sum_j (y_j - \hat{y}_j^{bench})^2}. \quad (3.13)$$

4. План экспериментов и интерпретации

4.1. Ablation study

Сценарии: A0 — только лаги ВРП; A1 — лаги + производственный блок; A2 — лаги + инвестиционный; A3 — лаги + социально-трудовой; A4 — лаги + бюджетный; A5 — все числовые признаки без региональной типологии; A6 — полный набор с типологией; A7 — все признаки без кризисных

dummy; A8 — полный набор без Москвы, ХМАО, ЯНАО и Сахалинской области.

4.2. Robustness checks

Четыре группы проверок. Первая — исключение крупнейших регионов и структурных выбросов. Вторая — альтернативные целевые переменные. Третья — сравнение expanding и rolling window. Четвёртая — раздельная оценка для кризисных лет 2008–2009, 2014–2015, 2020, 2022–2023.

4.3. SHAR-интерпретация

Прогноз: $\hat{y}_{i,t} = \phi_0 + \sum_{j=1}^p \phi_{j,i,t}$. Глобальный анализ: $I_j = \frac{1}{n} \sum_{i,t} |\phi_{j,i,t}|$. Групповой: $I_{j,g} = \frac{1}{n_g} \sum_{(i,t) \in g} |\phi_{j,i,t}|$. Локальный — для отдельных субъектов. SHAR применяется как инструмент объяснения модели, а не причинной идентификации [15].

4.4. Анализ ошибок

По регионам: $MAE_i = \frac{1}{T_i} \sum_t |y_{i,t} - \hat{y}_{i,t}|$. По годам: $MAE_t = \frac{1}{N_t} \sum_i |y_{i,t} - \hat{y}_{i,t}|$. По группам: $MAE_g = \frac{1}{|G|} \sum_{(i,t) \in G} |y_{i,t} - \hat{y}_{i,t}|$.

4.5. Сценарный прогноз на 2025–2026 годы

$$\hat{y}_{i,2025}^{sc} = f_{\theta}(X_{i,2024}^{sc}), \quad \hat{y}_{i,2026}^{sc} = f_{\theta}(X_{i,2025}^{sc}). \quad (4.1)$$

Рассматриваются инерционный, инвестиционный, промышленный, сырьевой и бюджетный сценарии. Прогноз на 2026 год несёт накопленную ошибку из-за прогнозных значений признаков 2025 года.

4.6. Ожидаемые результаты и ограничения

Ожидается, что лаги ВРП окажутся наиболее сильными предикторами; ключевой вопрос — дают ли производственные, инвестиционные и бюджетные признаки прирост сверх лагов. Не исключён сценарий, при котором регуляризованные линейные модели оказываются сопоставимы с бу-

стинговыми, — это означало бы, что короткая панель ограничивает выгоду от нелинейных алгоритмов.

Ограничения: (1) около двадцати годовых наблюдений на регион; (2) ретроспективная база не воспроизводит *real-time environment*; (3) структурные разрывы затрудняют перенос модели между режимами; (4) типология регионов условна; (5) SHAP не доказывает причинности.

5. Заключение

В работе задача прогнозирования ВРП субъектов Российской Федерации сформулирована как регрессия на панельных временных данных. Экономическая часть определяет предметную область, выбор признаков и критерии интерпретации; техническая часть задаёт воспроизводимый *pipeline*, процедуры предотвращения *leakage*, временную валидацию, сопоставление моделей, *ablation study* и SHAP-анализ.

Ключевая методологическая позиция: ансамблевые методы не являются самоцелью. Их применение должно быть оправдано устойчивым улучшением прогноза относительно базовых моделей. Отличительная черта исследования — включение GPBoost, совмещающего бустинг со случайными эффектами регионов, что позволяет напрямую адресовать панельную гетерогенность.

Если ансамблевые модели демонстрируют устойчивое преимущество, это станет аргументом в пользу их использования в региональном прогнозировании; если нет — работа фиксирует условия, при которых более простые эконометрические модели остаются предпочтительными.

Список литературы

- [1] Федеральная служба государственной статистики. Валовой региональный продукт за 2024 год. URL: <https://rosstat.gov.ru/folder/313/document/279001>.
- [2] Chi T.C., Fan T.-H., Ghigliazza R.M., Giannone D., Wang Z. Macroeconomic Forecasting and Machine Learning. arXiv:2510.11008, 2025.
- [3] Cerqua A., Letta M., Pinto G. On the (Mis)Use of Machine Learning With Panel Data. *Oxford Bulletin of Economics and Statistics*, 2025.
- [4] Бадыкова И. Р. Валовой региональный продукт: анализ детерминант для России с использованием моделей машинного обучения. *Экономика региона*, 2026. Т. 22. № 1. С. 97–108. DOI: 10.17059/ekon.reg.2026-1-8.
- [5] Lashina M., Grishunin S. Comparison of Forecasting Power of Statistical Models for GDP Growth Under Conditions of Permanent Crises. *Procedia Computer Science*, 2023. Vol. 221. P. 442–449. DOI: 10.1016/j.procs.2023.07.059.
- [6] Sigrist F. Gaussian Process Boosting. *Journal of Machine Learning Research*, 2022. Vol. 23. No. 232. P. 1–46.
- [7] Смирнов С. В. Методы машинного обучения в макроэкономическом прогнозировании: предварительные итоги. *Вопросы экономики*, 2025. № 10. С. 131–154. DOI: 10.32609/0042-8736-2025-10-131-154.
- [8] Цукарев Т., Погосян К., Лемба К., Гришин Д. Наукастинг ВВП: от традиционных эконометрических моделей к машинному обучению. *Рабочий документ ЕФСР*, РД/25/1, 2025. URL: <https://efsd.org/research/working-papers/>.
- [9] Макеева Н. М., Станкевич И. П. Наукастинг элементов использования ВВП России. *Экономический журнал ВШЭ*, 2022. Т. 26. № 4. С. 598–622. DOI: 10.17323/1813-8691-2022-26-4-598-622.

- [10] Foroni C., Marcellino M. A Survey of Econometric Methods for Mixed-Frequency Data. *Norges Bank Working Paper* 2013/06, 2013.
- [11] Малкина М.Ю., Сочков А.Л., Капустина Ю.И. Прогнозирование ВРП региона с применением методов искусственного интеллекта. *Journal of New Economy*, 2025. Т. 26. № 3. С. 67–85. DOI: 10.29141/2658-5081-2025-26-3-4.
- [12] Semiturkin O., Shevelev A. Forecasting Regional Inflation Rates Using Machine Learning Methods: The Case of Siberia Macroregion. *Bank of Russia Working Paper Series*, No. 91, 2022.
- [13] Chernyshova G.Yu., Rasskazkin N.D. Software Implementation of Ensemble Models for the Analysis of Regional Socio-Economic Development Indicators. *Izvestiya of Saratov University. Mathematics. Mechanics. Informatics*, 2022. Vol. 22. Iss. 1. P. 130–137. DOI: 10.18500/1816-9791-2022-22-1-130-137.
- [14] Buckmann M., Potjagailo G. Infusing Economically Motivated Structure into Machine Learning Methods. *Bank of England Staff Working Paper*, 2025.
- [15] Attolico L. Explainable Machine Learning for Macroeconomic and Financial Nowcasting. arXiv:2512.00399, 2025.
- [16] Lundberg S.M., Lee S.-I. A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems*, 2017.
- [17] Breiman L. Random Forests. *Machine Learning*, 2001. Vol. 45. P. 5–32.
- [18] Chen T., Guestrin C. XGBoost: A Scalable Tree Boosting System. *Proceedings of KDD*, 2016.
- [19] Ke G., Meng Q., Finley T., et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems*, 2017.
- [20] Dorogush A.V., Ershov V., Gulin A. CatBoost: Gradient Boosting with Categorical Features Support. arXiv:1810.11363, 2018.